

CS168：现代算法工具箱

第 7 讲：理解和使用主成分分析 (PCA)

Tim Roughgarden 与 Gregory Valiant

2024 年 4 月 23 日

1 一个玩具例子

下面这个玩具例子展示了主成分分析 (principal component analysis, PCA) 所解决的问题，也说明了为什么你可能想把它用于一个数据集：在更低维的空间中可视化数据，理解数据中变异性的来源，以及理解数据点不同坐标之间的相关性。

假设你请几位朋友按照 1 到 10 的量表，给四种不同食物打分：羽衣甘蓝沙拉、Taco Bell、生鱼片和 Pop-Tarts，结果如表 1 所示。按照我们通常的记号， m (数据点个数) 为 4， n (维度数) 也为 4。注意，与线性回归的情形不同，这些数据点没有任何形式的“标签” (除了人的名字之外)。我们能否把这个数据集有用地可视化到少于 4 个维度中？我们能否理解各种食物评分差异背后的力量？

	羽衣甘蓝沙拉	Taco Bell	生鱼片	Pop-Tarts
Alice	10	1	2	7
Bob	7	2	1	10
Carolyn	2	9	7	3
Dave	3	6	10	2

表 1：你的朋友对四种不同食物的评分。

图 1 示意：在平面中可视化 4 维数据。四个朋友大致位于由两个方向 v_1 与 v_2 张成的二维坐标系的四个象限中。

关键观察是，每一行 (一个数据点) 都可以近似表示为

$$\bar{x} + a_1 v_1 + a_2 v_2, \tag{1}$$

其中

$$\bar{x} = (5.5, 4.5, 5, 5.5)$$

是这些数据点的平均值，

$$v_1 = (3, -3, -3, 3), \quad v_2 = (1, -1, 1, -1),$$

而 (a_1, a_2) 对 Alice、Bob、Carolyn、Dave 分别是 $(1, 1)$ 、 $(1, -1)$ 、 $(-1, -1)$ 、 $(-1, 1)$ (见图 1)。例如， $\bar{x} + v_1 + v_2 = (9.5, 0.5, 3, 7.5)$ ，它近似等于 Alice 的评分。类似地， $\bar{x} - v_1 - v_2 = (1.5, 8.5, 7, 3.5)$ ，它近似等于 Carolyn 的评分。

这样的近似有什么用？一个答案是，它提供了可视化数据点的方法，如图 1 所示。如果数据点更多，我们可以想象检查得到的图形，寻找相似数据点形成的簇。

第二个答案是，它有助于解释数据。我们可以把每个数据点看成有一个“ v_1 坐标”（即 a_1 ）和一个“ v_2 坐标”（即 a_2 ）。向量 v_1 的“含义”是什么？它的第一和第四个坐标都具有较大的正值（因此二者正相关），第二和第三个坐标都具有较大的负值（因此二者彼此正相关，并且与第一、第四个坐标负相关）。注意到羽衣甘蓝沙拉和 Pop-Tarts 是素食¹，而 Taco Bell 和生鱼片不是，所以我们可以把 v_1 坐标解释为某个人偏好素食的程度。² 用类似的推理，我们可以把第二个向量 v_2 解释为一个人注重健康的程度。 v_1 的坐标幅度比 v_2 更大，这说明它是两个效应中更强的那个。

我们将看到，向量 v_1 和 v_2 在归一化之后，对应于该数据的“前两个主成分”。PCA 的要点就是自动计算形如式 (1) 的近似，包括对大型数据集也是如此。

1.1 PCA 的目标

PCA 的目标是把 m 个 n 维向量³ $x_1, \dots, x_m \in \mathbb{R}^n$ ，近似表示为 k 个 n 维向量 $v_1, \dots, v_k \in \mathbb{R}^n$ 的线性组合，即对每个 $i = 1, 2, \dots, m$,

$$x_i \approx \sum_{j=1}^k a_{ij} v_j.$$

(在这个玩具例子中， $m = n = 4$ 且 $k = 2$ 。) PCA 对于哪些 k 个向量在这个意义下“最好”给出了形式化定义。下一讲我们会看到，也有好的算法可以计算这些向量。

1.2 与降维的关系

PCA 的高层目标应该会让你想起前面讲过的几个主题。首先回忆 Johnson–Lindenstrauss (JL) 降维 (第 4 讲)，那里目标同样是把一堆高维点重新表示为低维点。回忆一下，该方法把一个点 x 映射为

$$(\langle x, r_1 \rangle, \dots, \langle x, r_k \rangle),$$

其中每个 r_j 是一个随机单位向量（每个坐标取独立标准高斯，然后归一化）。⁴ 对所有数据点使用相同的 r_j 。PCA 与 JL 降维有以下差别。

1. JL 降维假设你关心每一对点之间的欧氏距离；它被设计用来近似保持这些距离。PCA 不保证保持两两距离。
2. JL 降维是数据无关的：随机向量 $r_1, \dots, r_k$ 的选择不查看数据点。相比之下，PCA 是确定性的，其全部要点就是计算能“解释数据”的向量 $v_1, \dots, v_k$ 。
3. 由于上述原因，JL 降维使用的 k 个坐标没有内在含义，而 PCA 使用的坐标常常是有意义的（回忆玩具例子）。
4. JL 降维通常只有在 k 至少达到几百的低端时才会给出好结果。另一方面，对给定规模的每个数据集，这样的 k 都适用。PCA 即使在 $k = 1$ 或 $k = 2$ 时也能给出有意义的结果，但也存在一些数据集，无论 k 取多少，它都几乎不能提供有趣信息。

¹鲜为人知的事实：Pop-Tarts 至少未覆糖霜的种类，是无意中符合纯素标准的。

²反过来，如果我们知道哪些朋友是素食者、哪些不是，我们也可以推断哪些食物最可能是素食。

³例如可表示：图像（维度 = 像素）、测量值（维度 = 传感器）、文档（维度 = 词）等等。

⁴记号 $\langle x, y \rangle$ 表示两个向量的内积（或点积） $\sum_{i=1}^n x_i y_i$ 。

1.3 与线性回归的关系

PCA 和线性回归都涉及为点集拟合“最佳”的 k 维子空间。二者的一个差别在于输入数据的解释。在线性回归中，每个数据点都有一个实值标签，可以把它解释为一个特殊的“标签坐标”。线性回归的目标是学习这个特殊坐标与其他坐标之间的关系。当“标签”是一个因变量，并且近似等于所有其他坐标（自变量）的线性组合时，这样做是合理的。相比之下，在 PCA 中，所有坐标都被平等对待，并且不假设它们彼此独立。当存在一组潜在（即隐藏的/底层的）变量，而数据的所有坐标都是这些变量的（近似）线性组合时，PCA 是合理的。

第二，PCA 和线性回归对“最佳拟合”的定义不同。回忆线性回归中的目标是最小化总平方误差，其中一个数据点上的误差是线性函数的预测值与该数据点实际标签之间的差。对一维数据（连同标签）而言，这对应于计算一条直线，使得该直线与数据点之间的竖直距离平方和最小（图 2(a)）。这反映了一个假设：标签对应的坐标是重要坐标。下面我们将正式定义 PCA 的目标函数；对二维数据而言，目标是计算一条直线，使它与数据点之间的垂直距离平方和最小（图 2(b)）。这反映了另一个假设：所有坐标都发挥对称作用，因此通常的欧氏距离最合适（例如，旋转点集只会导致“最佳拟合”直线相应地旋转）。在第 4 个小项目中，你会进一步学习哪些情形适合 PCA，哪些情形适合线性回归。

图 2：线性回归最小化竖直距离平方和，而 PCA 最小化垂直距离平方和。

图 3：缩放 x 轴会产生不同的最佳拟合直线。

2 定义问题

2.1 预处理

在使用 PCA 之前，对数据进行预处理很重要。首先，点 $x_1, \dots, x_m$ 应当围绕原点居中，也就是 $\sum_{i=1}^m x_i$ 应为全零向量。这很容易实现：从每个点中减去（即平移）“样本均值”

$$\bar{x} = \frac{1}{m} \sum_{i=1}^m x_i.$$

（在玩具例子中， $\bar{x} = (5.5, 4.5, 5, 5.5)$ 。）对平移后的点集找到最佳拟合直线之后，只需把这条直线再按原来的样本均值平移回去，就得到原始未居中数据集的最佳拟合直线。这个平移技巧会让所需的线性代数更简单、更清晰。

其次，在许多应用中，适当地缩放每个坐标很重要。最常见的方法是：如果 $x_1, \dots, x_m$ 是一个以原点为中心的点集，那么对每个坐标 $j = 1, 2, \dots, n$ ，把每个点的第 j 个坐标除以该坐标上的“样本偏差”

$$\sqrt{\sum_{i=1}^m x_{ij}^2}.$$

进行这种坐标缩放的动机是：如果不这样做，PCA 的结果会对每个坐标的计量单位高度敏感。例如，在某个坐标上把单位从英里改成公里，从某种意义上说得到的是“同一个”数据集，但这个变化会放大该坐标中的所有值，继而导致计算出不同的“最佳拟合”直线。⁵ 在某些应用中，例如图

⁵即使在二维中，从几何上也应当清楚，拉伸某一个坐标会影响穿过这些点的最佳直线。另见图 3。

像，其中所有坐标单位相同，即像素强度，就没有必要做这种坐标缩放。（第 1 节的玩具例子也是如此。）

图 4：单位长度向量 w 的内积几何。 $\langle x_i, w \rangle$ 是 x_i 在由 w 张成的直线上的有符号投影长度。

2.2 目标函数

为清楚起见，我们先讨论 $k = 1$ 的特殊情形，也就是目标是给数据集拟合“最好”的一条直线。本节中的所有内容都容易推广到一般的 k （见第 2.3 节）。

如前所述，PCA 把“最佳拟合直线”定义为使直线与数据点之间平均欧氏距离平方最小的直线：

$$\arg \min_{v: \|v\|=1} \frac{1}{m} \sum_{i=1}^m (x_i \text{ 与由 } v \text{ 张成的直线之间的距离})^2. \quad (2)$$

注意，我们用同方向的单位向量 v 来表示一条（过原点的）直线。最小化点与所选直线之间的欧氏距离看起来相当自然；你可能唯一会疑惑的是，为什么要先把这些距离平方再相加。一个原因是，这保证了最佳拟合直线通过原点。另一个原因是它与方差最大化有紧密联系，下面马上讨论。

回忆投影和内积的几何（图 4）。特别地， $\langle x_i, v \rangle$ 是 x_i 在由 v 张成的直线上的（有符号）投影长度。再回忆勾股定理：对一个直角三角形，如果两条直角边为 a 和 b ，斜边为 c ，则 $a^2 + b^2 = c^2$ 。把它用于图 4 中的直角三角形，我们有

$$(\text{dist}(x_i, \text{line}))^2 + \langle x_i, v \rangle^2 = \|x_i\|^2. \quad (3)$$

式 (3) 右侧是常数，与直线 v 的选择无关。因此，一个点 x_i 到由 v 张成的直线的距离平方，与 x_i 在这条直线上的投影长度平方之间存在零和关系：让其中一个量变大，就会让另一个量变小。这说明，最大化投影平方和，也就是最大化点集投影的方差，与式 (2) 中原始目标等价：

$$\arg \max_{v: \|v\|=1} \frac{1}{m} \sum_{i=1}^m \langle x_i, v \rangle^2. \quad (4)$$

最大化方差这个目标函数本身也很自然；PCA 的目标函数拥有多种解释这一事实，让人更有信心相信它正在对数据执行一种基础性操作。举例来说，想象数据点落入两个分离良好的簇；图 5 给出了示意，但你也可以想象一个不容易用肉眼看出的高维版本。在这种情况下，最大化方差对应于在投影后保留两个簇之间的分离。（如果选择了一条很差的直线，两个簇会投影到彼此之上，从而遮蔽数据中的结构。）

图 5：对好的直线而言，把点投影到该直线上仍能保持两个簇分离；投影到差的直线上则会把两个簇合并。

PCA 实际上假设数据中的方差对应于有趣的信息。可以想象一些场景，在这些场景中，这种方差对应的是噪声而不是信号；此时 PCA 可能不会产生有启发性的结果。（关于 PCA 的失败情形，见第 4 节。）

2.3 更大的 k 值

到目前为止的讨论集中在 $k = 1$ 的情形（为数据拟合一条直线），但更大 k 的情形几乎一样。对一般的 k ，最小化到一个 k 维子空间的距离平方和，与最大化到一个 k 维子空间的投影方差，这两个目标函数仍然等价。因此，PCA 的目标现在是

$$\arg \max_{k \text{ 维子空间 } S} \frac{1}{m} \sum_{i=1}^m (x_i \text{ 在 } S \text{ 上的投影长度})^2. \quad (5)$$

为了把这个目标改写成更方便的形式，回忆如下基本线性代数。首先，向量 $v_1, \dots, v_k$ 称为标准正交的，如果它们都具有单位长度（对所有 i ， $\|v_i\| = 1$ ）并且两两正交（对所有 $i \neq j$ ， $\langle v_i, v_j \rangle = 0$ ）。例如，标准基向量（形如 $(0, 0, \dots, 0, 1, 0, \dots, 0)$ ）是标准正交的。旋转这些向量会得到更多组标准正交向量。

一组向量 $v_1, \dots, v_k \in \mathbb{R}^n$ 的张成空间，是它们所有线性组合的集合：

$$\left\{ \sum_{j=1}^k \lambda_j v_j : \lambda_1, \dots, \lambda_k \in \mathbb{R} \right\}.$$

如果 $k = 1$ ，这个张成空间就是一条过原点的直线；如果 $k = 2$ 且 v_1, v_2 线性无关（也就是彼此不是倍数），那么张成空间是一个（过原点的）平面；依此类推。

关于标准正交向量 $v_1, \dots, v_k$ ，一个很好的事实是：一个点到这些向量所张成子空间上的投影长度平方，正好等于它在每个向量上的投影平方之和：

$$(x_i \text{ 在 } \text{span}(v_1, \dots, v_k) \text{ 上的投影长度})^2 = \sum_{j=1}^k \langle x_i, v_j \rangle^2. \quad (6)$$

（为了建立直觉，先考虑 $v_1, \dots, v_k$ 都是标准基向量的情形，此时 $\langle x_i, v_j \rangle$ 只是取出 x_i 的某一个坐标。）如果 v_j 们不是标准正交的，这个恒等式就不成立（例如想象 $k = 2$ ， v_1, v_2 线性无关但几乎是同一个向量）。

结合式 (5) 和式 (6)，我们可以用标准形式陈述一般 k 下 PCA 的目标：计算标准正交向量 $v_1, \dots, v_k$ ，使

$$\frac{1}{m} \sum_{i=1}^m \sum_{j=1}^k \langle x_i, v_j \rangle^2 \quad (7)$$

最大。得到的这 k 个标准正交向量称为数据的前 k 个主成分。⁶

概括一下，PCA 所解决问题的形式化定义是：

给定 $x_1, \dots, x_m \in \mathbb{R}^n$ 和参数 $k \geq 1$ ，计算标准正交向量 $v_1, \dots, v_k \in \mathbb{R}^n$ ，使式 (7) 最大。

下一讲我们会讨论寻找前 k 个主成分的计算方法。本讲最后讨论 PCA 的使用场景和“不使用场景”（也就是失败模式）。如果有一个可以计算主成分的黑盒，你会用它做什么？

⁶在玩具例子中，两个向量 $(3, -3, -3, 3)$ 和 $(1, -1, 1, -1)$ 在归一化为单位向量之后，接近前两个主成分。真正的主成分数值更杂乱，所以这里不列出。试试用一行 Matlab 代码计算它们！

3 使用场景

3.1 数据可视化

3.1.1 一般配方

PCA 常用于可视化数据。在这个使用场景中，通常取 k 为 1、2 或 3。给定数据点 $x_1, \dots, x_m \in \mathbb{R}^n$ ，方法如下：

1. 执行 PCA，得到前 k 个主成分 $v_1, \dots, v_k \in \mathbb{R}^n$ 。
2. 对每个数据点 x_i ，把它的“ v_1 坐标”定义为 $\langle x_i, v_1 \rangle$ ，“ v_2 坐标”定义为 $\langle x_i, v_2 \rangle$ ，依此类推。这样就根据 x_i 与前 k 个主成分中每个方向的一致程度，为每个数据点关联了 k 个坐标。（因此，一个很大的正坐标表示 x_i 接近于 v_j 的同方向；一个很大的负坐标表示 x_i 指向相反方向。）
3. 在 $\mathbb{R}^k$ 中把点 x_i 画成点

$$(\langle x_i, v_1 \rangle, \dots, \langle x_i, v_k \rangle).$$

7

这或多或少就是我们在图 1 的玩具例子中所做的事，虽然缩放不同，因为我们的向量 v_1 和 v_2 不是单位向量。

点 $(\langle x_i, v_1 \rangle, \dots, \langle x_i, v_k \rangle)$ 的“含义”是什么？回忆一下，理解 PCA 的一种方式：它用同样的 k 个向量的线性组合来近似一堆数据点。PCA 为此使用向量 $v_1, \dots, v_k$ ，而坐标 $(\langle x_i, v_1 \rangle, \dots, \langle x_i, v_k \rangle)$ 指定了这些向量的线性组合，使其在欧氏距离意义下最接近 x_i 。也就是说，PCA 把每个 x_i 近似为

$$x_i \approx \sum_{j=1}^k \langle x_i, v_j \rangle v_j.$$

3.1.2 解释结果

v_j 们以及 x_i 在它们上面的投影都可能很有趣。下面是一些可以查看的内容：

1. 查看在第一主成分上的投影 $\langle x_i, v_1 \rangle$ 最大（最正）和最小（最负）的数据点。这是否暗示了该成分的潜在“含义”？在两端是否有数据点聚在一起？如果有，它们有什么共同点？
2. 按照所有点的 k 个坐标值（即到前 k 个主成分的投影长度）来绘制它们。是否会出现有趣的簇（例如当 $k = 2$ 时，四个角落中的某些簇）？例如，通过观察第二坐标相近的点，包括第一坐标也相近的点，以及第一坐标差异很大的点，常常可以粗略解释第二主成分。
3. 查看某个主成分的坐标，也就是它所使用的原始数据点属性的线性组合，也可能有帮助。（例如见下面 Eigenfaces 的应用。）

图 6：文献 [1] 的图，把 1387 名欧洲人的基因组投影到前两个主成分上。数据点的颜色/标签对应个体的地理位置。右上角附有相同配色的欧洲地图作为参照。

⁷另一种做法是，有时使用前 k 个主成分的某个子集来画点会更有启发性，例如第一和第三个主成分。

3.1.3 基因组是否编码地理信息？

你能否从一个人的 DNA 推断其成长地点？在一项出色的研究中，Novembre 等人 [1] 使用 PCA 表明，在某些情况下答案是“可以”。这是一个案例研究，说明 PCA 如何揭示数据“知道”一些你并不会预期它知道的事情。

Novembre 等人 [1] 考虑了一个包含 1387 名欧洲人的数据集（这些人对应行）。每个人的基因组都在相同的 200,000 个“SNP”（列）上被检查，这些位置往往会出现基因突变。⁸ 因此在这些位置之一，可能 90% 的人是一个“C”，而 10% 的人是一个“A”。简而言之，Novembre 等人 [1] 对这个数据集应用 PCA（其中 $m \approx 1400$ ， $n \approx 200,000$ ， $k = 2$ ），并根据前两个主成分 v_1 和 v_2 来绘制数据（使用与第 3.1.1 节完全相同的配方，其中 x 轴和 y 轴分别对应 v_1 和 v_2 ）。⁹ 见图 6。

我们强调，这幅图只依赖基因组数据。为了进行解释，作者随后按照相应个体的原籍国家对每个绘出的点进行颜色编码（这些信息在元数据中可用）。查看文献 [1] 中的结果图（课程网页上可获得）：它基本上就是一幅欧洲地图！第一主成分 v_1 大致对应一个人来自哪里这一位置的纬度，而 v_2 对应经度（逆时针旋转 16 度）。也就是说，他们的基因组“知道”他们来自哪里！这表明许多欧洲人在本地繁衍的时间足够长，以至于地理信息反映在 DNA 中。

这个结论事后看来显然吗？并不完全。例如，如果你用美国数据重复这个实验，前几个主成分更多对应的是移民浪潮，而不是什么地理因素。因此在这种情形下，前几个主成分反映的是时间效应而不是空间效应。

关于遗传变异存在相互竞争的数学模型。其中一些涉及空间衰减，另一些则基于多个离散且区分良好的群体。Novembre 等人 [1] 的研究表明，对欧洲人而言，前一类模型更合适。

在用 PCA 分析数据（特别是基因组数据）时，有一点需要谨慎：前几个主成分往往只能解释数据总体方差的一小部分。尽管前几个主成分确实常常对应清晰可识别的特征（例如上述例子中的地理位置），这一点仍然成立。在这个基因组场景中，这些成分只解释小部分方差这一事实应当这样理解：是的，对某些人群，你的基因组可以给出你或你的家族来自哪里的准确估计。尽管如此，你基因组中大部分方差（它部分负责许多使你不同于其他人的属性）并没有被这些前几个主成分捕捉。

3.2 数据压缩

PCA 在计算机科学中的一个著名“杀手级应用”是 Eigenfaces 项目 [2]。在这里，数据点是一堆人脸图像：所有图像都以同样方式取景，并在相同照明条件下拍摄。因此， n 是像素数（约 65K），每个维度编码一个像素的强度。事实证明，只使用前 100 到 150 个主成分，就足以高精度表示几乎所有图像，远少于精确表示所有图像所需的 65K 维。¹⁰ 每个主成分都可以被看成一幅图像，并且在许多情况下可以直接解释。（相比之下，在前一个例子中，我们不能通过检查前两个主成分本身来解释它们；我们需要先绘制数据点。）例如，一个主成分可能表示是否戴眼镜，另一个可能表示是否有胡子，等等。（见课程网站上文献 [2] 中的图。）这些技术已经用于人脸识别，而人脸识别可以归结为在前几个主成分张成的低维空间中进行一种最近邻类型的计算。当然，自 1991 年文献 [2] 发表以来，人脸识别已有大量进展，但 PCA 仍然是许多现代机器学习数据流水线中的关键构件。

图 7：来自摩天轮的 GPS 数据。PCA 并不是为发现非线性结构而设计的。

⁸你将在第 4 个小项目中处理一个类似的数据集。

⁹与 PCA 的通常做法一样，为了获得最佳结果，需要对数据进行非平凡的预处理。

¹⁰下一讲我们会看到，主成分实际上是某个合适矩阵的特征向量，因此有“Eigenfaces”这个名称。

4 失败情形

PCA 何时以及为什么会失败？

1. 你弄错了缩放/归一化。PCA 对不同坐标的缩放/归一化很敏感。要从 PCA 中获得好结果，很大一部分技艺在于为不同数据坐标选择合适的缩放方式，也可能还需要额外的数据预处理（例如去除离群点）。
2. 非线性结构。PCA 的全部内容都是在数据中寻找线性结构。如果你的数据具有某种低维但非线性的结构，例如你有两个数据坐标 x, y ，且 $y \approx x^2$ ，那么 PCA 找不到这种结构。¹¹ 来自某人在摩天轮上的 GPS 数据也是类似情形（图 7）：数据是一维的（每个点都可以由一个角度指定），但 PCA 不会识别出这个维度。
3. 非正交结构。拥有可解释的坐标很好，就像我们的玩具例子（第 1 节）和欧洲例子（第 3.1.3 节）中那样。即使你的数据本质上是线性的，主成分彼此都必须正交这一事实，常常也意味着在前几个成分之后，几乎不可能解释各个成分的含义。在欧洲例子中，第三个及之后的成分被迫与纬度和经度成分正交。把这样的约束施加在一个可解释特征上，是相当人为的。

参考文献

- [1] John Novembre, Toby Johnson, Katarzyna Bryc, Zoltán Kutalik, Adam R. Boyko, Adam Auton, Amit Indap, Karen S. King, Sven Bergmann, Matthew R. Nelson, Matthew Stephens, and Carlos D. Bustamante. *Genes mirror geography within Europe*. *Nature*, 456:98–101, 2008.
- [2] M. Turk and A. Pentland. *Eigenfaces for recognition*. *Journal of Cognitive Neuroscience*, 3(1):71–86, 1991.

原文版权说明：©2015–2024, Tim Roughgarden and Gregory Valiant. 未经作者同意，不得出售、出版或分发。本文档为按用户请求生成的中文译文版。

¹¹正如上一讲在线性回归语境中提到的，你总可以给数据增加额外的非线性维度，例如坐标 x^2, y^2, xy 等，然后在这个更高维数据上做 PCA。不过这个想法在 PCA 中并不总是效果很好。