

CS168：现代算法工具箱

第 8 讲：PCA 与幂迭代法

Tim Roughgarden & Gregory Valiant
中文翻译

2015 年 4 月 15 日

本讲一开始对第 7 讲作了较长的回顾。回忆一下，如果我们有一个矩阵 X ，其每一行表示一个数据点，那么可以找到一个标准正交矩阵 Q （行/列彼此正交，并且范数为 1）以及一个对角矩阵 D ，使得

$$X^t X = Q^t D Q.$$

在这样的分解下， Q 的各行就是 $X^t X$ 的特征向量，与之对应的特征值由对角矩阵 D 中相应的对角元素给出。

分解 $X^t X = Q^t D Q$ 是唯一的，差别只可能在于对 D 的对角元素作排列（同时对 Q 的各行作相应排列）。从现在开始，我们假设采用这样一种表示： D 的对角元素从左上到右下按递减顺序排列。

回忆一下，PCA 有若干用途：

- 作为降维工具。例如，我们想把高维数据表示为 k 维数据，一个自然的选择是取一个 k 维子空间，使它尽可能多地捕获数据点的长度。这个子空间正是由前 k 个主成分张成的空间。注意，这个子空间依赖于我们如何缩放数据；这不同于第 4 讲中看到的随机投影降维的 JL 工具。
- 作为数据去噪工具。也就是说，我们希望数据本质上是低维的，只是叠加了噪声。保留低维结构时，我们就在去除无结构的噪声。
- 作为揭示数据结构的工具。例如，我给出的欧洲基因组示例（见课程网页中的链接）表明，遗传 SNP 数据的前两个主成分对应于地理上的纬度和经度。

1 幂迭代法

如何计算前 k 个主成分？主要有两种方法：1) 显式计算分解 $X^t X = Q^t D Q$ ；2) 使用幂迭代法。第一种方法可以用符号方式完成，但基本上只适用于小矩阵，并且涉及计算矩阵 $X^t X$ 的“特征多项式”的根。实践中通常使用幂迭代法，尤其是在我们只想要前几个主成分的时候；它也能提供额外的直觉，帮助理解主成分究竟意味着什么。

幂迭代法背后的主要直觉是：如果把矩阵 $M = X^t X$ 看成一个把单位球映射到椭球的函数，那么椭球的最长轴对应于第一主成分。由于第一主成分对应的是乘以 M 时向量被拉伸得最多的方向，因此一个自然的希望是：如果从一个随机向量 v 出发，并反复不断地施加 M ，那么 v 在 M 的第一主成分方向上会被拉伸得非常多次，直到 v 的像几乎完全落在这个第一主成分的方向上。这就是幂迭代算法。下面将其形式化表述。

算法 1：幂迭代

给定矩阵 $M = X^t X$ ：

- 选择随机单位向量 v_0 。
- 对 $i = 1, 2, \dots$, 令 $v_i = M^i v_0$ 。如果

$$\frac{v_i}{\|v_i\|} \approx \frac{v_{i-1}}{\|v_{i-1}\|},$$

则返回 $\frac{v_i}{\|v_i\|}$ 。

通常，与其计算 $Mv_0, M^2v_0, M^3v_0, \dots, M^4v_0, M^5v_0$ ，不如使用反复平方的“技巧”，计算

$$Mv_0, M^2v_0, M^4v_0, M^8v_0, \dots$$

为了解释该算法为什么有效，我们首先证明：如果 $M = Q^t D Q$ ，那么 $M^i = Q^t D^i Q$ 。也就是说， M^i 与 M 具有相同的取向（即相同的特征向量），但所有特征值都被提升到了第 i 次方，因此差异会被放大。例如，如果 $\lambda_1 > 2\lambda_2$ ，那么 $\lambda_1^{10} > 1000\lambda_2^{10}$ 。

命题 1.1 如果 $M = Q^t D Q$ ，那么 $M^i = Q^t D^i Q$ 。

证明 我们对 i 作归纳。基例 $i = 1$ 显然成立。假设命题对某个特定的 $i \geq 1$ 成立，考虑：

$$M^{i+1} = M^i \cdot M = Q^t D^i Q Q^t D Q = Q^t D^i D Q = Q^t D^{i+1} Q.$$

其中第二个等号使用了归纳假设，第三个等号来自 Q 的正交性，因此可以把 $Q Q^t$ 替换为单位矩阵。□

现在我们可以量化幂迭代算法的表现。

定理 1.2 在随机选择 v_0 时，以至少 $1/2$ 的概率，对任意 $t \geq 1$ ，有

$$|\langle M^t v_0, w_1 \rangle| \geq 1 - 2\sqrt{d} \left(\frac{\lambda_2}{\lambda_1} \right)^t,$$

其中 w_1 是 M 的第一特征向量，其特征值为 λ_1 ，而 λ_2 是 M 的第二大特征值。特别地，如果

$$t > \frac{10 \log d}{\log(\lambda_1/\lambda_2)},$$

那么

$$|\langle v_t, w_1 \rangle| > 1 - 2e^{-20} > 0.99999,$$

也就是说， v_t 实质上已经指向与 w_1 相同的方向。

证明 令 $w_1, w_2, \dots$ 表示 M 的特征向量，对应特征值为 $\lambda_1, \dots$ 。我们可以把随机向量 v_0 表示在由 $w_1, w_2, \dots$ 定义的（未知）基底中，即

$$v_0 = c_1 w_1 + c_2 w_2 + \dots$$

我们声称，以至少 $1/2$ 的概率，有

$$|c_1| > \frac{1}{2\sqrt{d}}.$$

这是关于随机向量的一个简单事实：我们可以通过让每个坐标独立地从方差为 $1/d$ 的高斯分布中抽取，然后再作归一化，来选择一个随机单位向量；归一化因子会非常接近 1。

在 $|c_1| > 1/2$ (原讲义此处按其推导记述) 这一事实下, 可得到

$$|\langle M^t v_0, w_1 \rangle| = \frac{c_1 \lambda_1^t}{\sqrt{\sum_{i=1}^d (\lambda_i^t c_i)^2}} \geq \frac{c_1 \lambda_1^t}{\sqrt{c_1^2 \lambda_1^{2t} + d \lambda_2^{2t}}} \geq \frac{c_1 \lambda_1^t}{c_1 \lambda_1^t \sqrt{1 + \frac{\lambda_2^{2t} d}{\lambda_1^{2t}}}} \geq 1 - 2\sqrt{d} \left(\frac{\lambda_2}{\lambda_1} \right)^t.$$

□

注意, 上述“以概率 $1/2$ ”的说法可以通过重复上述算法 100 次 (每次独立选择 v_0), 并输出使 $\|Mv\|$ 最大的恢复向量 v , 替换为“以至少 $1 - 1/2^{100}$ 的概率”。

上述定理表明, 我们所需的幂迭代次数按

$$\frac{\log d}{\log(\lambda_1/\lambda_2)}$$

的规模增长。如果 λ_1/λ_2 很大, 那么情况非常好。如果 $\lambda_1 \approx \lambda_2$, 那么算法可能需要很长时间才能找到 w_1 , 甚至可能永远找不到。注意, 如果 $\lambda_1 = \lambda_2$, 那么 w_1 和 w_2 并不是唯一定义的; 任何位于这个二维空间中一对标准正交向量都将是特征值为 $\lambda_1 = \lambda_2$ 的特征向量。在这种情况下, 幂迭代算法只会返回一个位于该子空间中的向量, 而这正是应当得到的结果。

1.1 寻找多个主成分

幂迭代算法可以找到第一主成分。如果我们想找到前 k 个主成分, 可以这样做:

1. 使用幂迭代找到第一主成分 w_1 。
2. 将数据正交投影到 w_1 的正交补上。具体地, 对每个数据点 x , 把它替换为

$$x - w_1 \langle x, w_1 \rangle.$$

3. 递归地在新数据上寻找前 $k - 1$ 个主成分; 在这个新数据中, 方向 w_1 已经被移除。

这个贪心算法的正确性立即来自如下事实: 使数据矩阵 X 的投影范数最大的 k 维子空间, 包含使投影范数最大的 $k - 1$ 维子空间。

1.2 特征谱

你如何知道应该找多少个主成分? 简单回答是: 你不知道。一般来说, 值得计算许多个主成分, 并考察特征谱, 也就是特征值的集合。通常, 如果你把特征值画出来, 会看到在某个点之后, 它们都相当小。例如, 你的数据可能有 200 维, 但在前 50 个特征值之后, 剩下的都很小。观察这张图可能会给你一些启发式感觉, 帮助选择主成分个数, 从而在尽可能保留数据低维性的同时, 最大化数据信号。

2 失败情形

PCA 什么时候会失败? 为什么会失败?

1. 你把缩放或归一化弄错了。PCA 对坐标的不同缩放/归一化非常敏感。让 PCA 得到好结果的很大一部分“艺术”在于为不同的数据坐标选择合适的缩放方式。
2. 非线性结构。PCA 要寻找的是数据中的线性结构。如果你的数据有某种低维但非线性的结构, 例如有两个数据坐标 x, y , 且 $y \approx x^2$, 那么 PCA 找不到它。注意: 当然, 你总是可以向数据中加入额外的非线性维度, 例如加入坐标 x^2, y^2, xy 等, 然后对这个更高维的数据做 PCA。你甚至可以用核化的方式来做。如果你还没有在其他课里见过核技巧, 不必担心这最后一句评论。

3. 非正交结构。拥有可解释的坐标是很好的。即使你的数据本质上是线性的，主成分彼此都正交这一事实也常常意味着，在前 3 或 4 个成分之后，几乎不可能解释这些成分的含义。这是因为，例如第 5 个成分被强制要求与前 4 个成分正交；而把这种人为约束加在一个可解释特征上，是相当不自然的。

3 幂迭代、主成分与马尔可夫链

课上我没有时间提到这一点，但因为课后有人问起，所以想在这里作一个说明。（不用担心，这不会出现在考试中。）

你可能还记得第 6 讲马尔可夫链中的表达式 $M^t \cdot v$ 。在那一讲中， M 是马尔可夫链的转移矩阵， v 是初始状态（或状态上的分布），并且

$$\lim_{t \rightarrow \infty} M^t v = \pi,$$

其中 π 满足 $M^t \pi = \pi$ ，是马尔可夫链的平稳分布，也就是极限分布；前提是这样的分布存在。（回忆马尔可夫链基本定理的两个条件：每个状态最终都必须能从任何其他状态到达，并且链不能是“周期性”的。）经过今天的讲解，应该很清楚， π 是转移矩阵 M 的第一特征向量，而运行 MCMC（或显式计算 $M^t v$ ）本质上都是在应用幂迭代法，来寻找这个极限的“平稳”分布。

在本讲中， $M = X^t X$ 是对称矩阵；而马尔可夫链的典型转移矩阵 M 可能并不对称。主要区别在于，对于一个非对称的转移矩阵 M ，我们会遇到负特征值，相关解释和直觉也会稍微复杂一些，尽管许多思想仍然适用。课程最后一周我们会进一步讨论当把 PCA 应用于转移矩阵时会发生什么。