

CS168：现代算法工具箱

第 9 讲：奇异值分解（SVD）与低秩矩阵近似

Tim Roughgarden 与 Gregory Valiant*

2024 年 4 月 30 日

1 缺失项是什么？

先来出一道小测验：考虑下面这个 5×3 矩阵，其中有 7 个元素已知，8 个元素缺失：

$$\begin{bmatrix} 7 & ? & ? \\ ? & 8 & ? \\ ? & 12 & 6 \\ ? & ? & 2 \\ 21 & 6 & ? \end{bmatrix}.$$

这些缺失项分别是什么？

这个矩阵补全问题看起来有点不公平，对吧？毕竟，每个未知项都可以是任意数，我们似乎没有办法知道它们是什么。但如果我再告诉你一个额外提示：完整矩阵具有“良好结构”呢？这可以有很多含义；在这个例子里，我们采用一个很极端的假设：所有行都是彼此的倍数。

现在就可以恢复所有缺失项了！例如，如果第三行是第二行的倍数，那么由于中间列里的 12 和 8，第二行的每个元素都必须是第三行对应元素的 $\frac{2}{3}$ 。因此可以推出第二行第三个元素是 4。类似地，第四行中间的元素是 4，最后一行最后的元素是 3，依此类推。补全后的矩阵为

$$\begin{bmatrix} 7 & 2 & 1 \\ 28 & 8 & 4 \\ 42 & 12 & 6 \\ 14 & 4 & 2 \\ 21 & 6 & 3 \end{bmatrix}. \tag{1}$$

这个例子的要点是：当你知道一个部分已知矩阵具有某种“结构”时，有时就能恢复所有“丢失”的信息。假设所有行互为倍数当然非常极端，那么更一般地说，“矩阵结构”应该是什么意思？下一节会解释一个自然且有用的定义：低秩。

*©2016–2024, Tim Roughgarden and Gregory Valiant. 未经作者同意，不得出售、出版或分发。

2 矩阵的秩

你可能已经在以前的课程中见过矩阵秩的概念，不过我们还是花一点时间回顾相关概念。

秩为 0 的矩阵。 给定大小的秩零矩阵只有一个，也就是全零矩阵。

秩为 1 的矩阵。 秩一矩阵正是上面例子所假设的那类非零矩阵：所有行都是彼此的倍数（不一定是整数倍）。在式 (1) 的例子中，所有列也互为倍数；这并不是巧合。

对一个秩为 1 的 $m \times n$ 矩阵，等价定义是它可以写成一个 m 维向量 u 与一个 n 维向量 v 的外积 $uv^\top$ ：¹

$$A = uv^\top = \begin{bmatrix} u_1 v^\top \\ u_2 v^\top \\ \vdots \\ u_m v^\top \end{bmatrix} = \begin{bmatrix} v_1 u & v_2 u & \cdots & v_n u \end{bmatrix}.$$

注意，每一行都是 $v^\top$ 的倍数，每一列都是 u 的倍数。

秩为 2 的矩阵。 秩二矩阵就是两个秩一矩阵的叠加（也就是和）：

$$A = uv^\top + wz^\top = \begin{bmatrix} u_1 v^\top + w_1 z^\top \\ u_2 v^\top + w_2 z^\top \\ \vdots \\ u_m v^\top + w_m z^\top \end{bmatrix} = \begin{bmatrix} u & w \end{bmatrix} \begin{bmatrix} v^\top \\ z^\top \end{bmatrix}. \quad (2)$$

值得花些时间检查并消化式 (2) 中的等式。

严格地说还差一点：秩二矩阵是能够写成两个秩一矩阵之和、但它本身既不是秩零也不是秩一的矩阵。

秩为 k 的矩阵。 矩阵秩的一般定义现在应该很清楚了：如果矩阵 A 可以写成 k 个秩一矩阵之和，并且不能写成 $k-1$ 个或更少秩一矩阵之和，那么 A 的秩为 k 。

用矩阵乘法来重新表述，一个等价定义是： A 可以写成，或者说“分解”为，一个又高又瘦的 $m \times k$ 矩阵 Y 与一个又矮又宽的 $k \times n$ 矩阵 $Z^\top$ 的乘积：

$$A = YZ^\top.$$

并且 A 不能类似地分解为一个 $m \times (k-1)$ 矩阵和一个 $(k-1) \times n$ 矩阵的乘积。

$$\underbrace{A}_{m \times n} = \underbrace{Y}_{m \times k} \underbrace{Z^\top}_{k \times n}$$

图 1：任意秩为 k 的矩阵 A 都可以分解为一个又高又瘦的矩阵乘以一个又矮又宽的矩阵。

¹这与内积（也称点积） $u^\top v = \sum_{i=1}^n u_i v_i$ 形成对比。内积只对同维向量有定义，结果是一个标量。

矩阵 A 的秩有很多等价定义。下面两个条件彼此等价，也与上面的定义等价（三个条件中任意一个都推出另外两个）：

1. A 的列中，最大的线性无关子集大小为 k 。也就是说， A 的全部 n 列都可以由其中 k 列线性组合得到。
2. A 的行中，最大的线性无关子集大小为 k 。也就是说， A 的全部 m 行都可以由其中 k 行线性组合得到。

第一个定义推出后两个条件是显然的：如果 $A = YZ^T$ ，那么 A 的所有列都是 Y 的 k 列的线性组合， A 的所有行都是 Z^T 的 k 行的线性组合。其他方向的证明可参见线性代数课程（并不难）。

3 低秩矩阵近似：动机

本讲的主要目标是：给定矩阵 A 和目标秩 k ，找出用秩 k 矩阵近似 A 的“最佳”方式。这样的矩阵称为低秩近似。为什么会想这么做？

1. **压缩**。低秩近似提供了矩阵的（有损）压缩版本。原矩阵 A 需要用 mn 个数字描述，而描述 Y 和 Z^T 只需要 $k(m+n)$ 个数字。当 k 相对 m, n 很小时，把 m 与 n 的乘积替换成它们的和会带来巨大收益。例如，当 A 表示一幅图像（元素为像素强度）时， m, n 通常是几百。在其他应用中， m, n 很可能达到数万甚至更大。对图像而言，一个适中的 k （比如 100 或 150）通常就足以得到看起来很像原图的近似。因此，低秩近似可以看成是向量降维概念（第 4 讲和第 7 讲）在矩阵上的对应物。
2. **更新巨型机器学习模型**。低秩矩阵近似的一个很现代的应用，是对巨型模型进行“微调”。在大语言模型（LLM）的场景中，常常有一个现成的巨大模型，带有数十亿甚至更多参数。给定这样一个在巨大但通用语料（网页文本）上训练出来的大模型，人们通常会进行“微调”。微调阶段是在领域特定数据集上进行第二轮训练，而这个数据集通常规模相当有限。微调任务的例子包括客服对话数据集、Ed 论坛问答、医疗报告等。不过微调的挑战在于，更新如此庞大的模型在计算上极其昂贵。2021 年论文 *LoRA: Low-Rank Adaptation of Large Language Models* [1] 论证了：1) 微调更新通常接近低秩；因此 2) 可以显式地以分解形式学习原模型的这些更新，本质上是在训练一个参数少 1000 倍甚至 10000 倍的模型！如果你感兴趣，可以看看原论文（或者讨论它的一大堆博客文章）。
3. **去噪**。如果 A 是某个近似低秩的“真实”信号的带噪版本，那么把原始数据 A 替换成它的低秩近似，可能会丢掉大量噪声而保留少量信号，从而得到一个实际上比原矩阵更有信息量的矩阵。
4. **矩阵补全**。低秩近似为第 1 节介绍的矩阵补全问题提供了一个初步方法。（第 9 周我们会看到更高级的方法。）给定一个有缺失项的矩阵 A ，第一步是用“默认”值填补缺失项，得到完整矩阵 $\hat{A}$ 。这些默认值究竟应该是什么，需要反复试验；该方法是否成功通常强烈依赖这个选择。自然可以尝试的默认值包括：0、同一列已知项的平均值、同一行已知项的平均值，以及整个矩阵已知项的平均值。第二步是计算 $\hat{A}$ 的最佳秩 k 近似。当未知矩阵接近秩 k 矩阵且缺失项不太多时，这种方法表现相当不错。

我们计算矩阵 A 的秩 k 近似的高层计划是：(i) 把 A 表示为按“重要性”排序的成分列表；(ii) 只保留最重要的 k 个成分。非平凡的步骤 (i) 会由奇异值分解轻松完成，下

一节会讨论这一通用矩阵操作。

4 奇异值分解 (SVD)

4.1 定义

我们先给出形式化定义，然后再讨论解释、应用，以及它与前几讲概念的联系。一个 $m \times n$ 矩阵 A 的奇异值分解 (SVD) 把矩阵表示为三个“简单”矩阵的乘积：

$$A = USV^T, \quad (3)$$

其中：

1. U 是一个 $m \times m$ 正交矩阵；²
2. V 是一个 $n \times n$ 正交矩阵；
3. S 是一个 $m \times n$ 的对角矩阵，元素非负，并且对角元素从大到小排序（从“西北”到“东南”方向）。³

注意，这与第 8 讲讨论的分解（当 A 形如 $X^T X$ 时有 $A = QDQ^T$ ）不同：这里的正交矩阵 U 和 V 不相同。由于 A 不一定是方阵， U 和 V 甚至不一定有相同维度。⁴

U 的列称为 A 的左奇异向量（它们是 m 维向量）。 V 的列（也就是 V^T 的行）称为 A 的右奇异向量（它们是 n 维向量）。 S 的元素是 A 的奇异值。因此，每个奇异向量（左或右）都有一个对应的奇异值。“第一个”或“顶部”奇异向量指的是与最大奇异值对应的那个，依此类推。

$$A = USV^T$$

图 2：奇异值分解 (SVD)。 S 中的每个奇异值都对应 U 中的一个左奇异向量，以及 V 中的一个右奇异向量。

为了更清楚地看到 SVD 如何把 A 表示成“成分列表”，可以验证分解 $A = USV^T$ 等价于

$$A = \sum_{i=1}^{\min\{m,n\}} s_i \cdot u_i v_i^T, \quad (4)$$

其中 s_i 是第 i 个奇异值， u_i, v_i 是对应的左、右奇异向量。也就是说，SVD 把 A 表示为 $\min\{m, n\}$ 个秩一矩阵的非负线性组合；奇异值提供系数，左、右奇异向量的外积提供秩一矩阵。

每个矩阵 A 都有 SVD。证明并不深，但比起在这里展开，更适合放在线性代数课程中。从几何角度看，把一个 $m \times n$ 矩阵看作从 $\mathbb{R}^n$ 到 $\mathbb{R}^m$ 的映射，这个事实相当惊人：任

²回忆上一讲：如果一个矩阵的列（等价地，行）是标准正交向量，即每个向量范数为 1，且任意两个不同向量的内积为 0，那么该矩阵是正交矩阵。

³当我们说一个（不一定方的）矩阵是对角矩阵时，意思就是你会想到的那样：只有形如 (i, i) 的元素允许非零。

⁴即使是很小的数值例子，完整手算也很繁琐；奇异向量的正交性约束会让大多数数字变得很 messy。想建立对 SVD 样子的直觉，最容易的方法是把几个小矩阵丢进你常用环境里的 SVD 子程序（Matlab、Python 的 numpy 库等）。

何矩阵 A ，不管多么古怪，都只是在定义域中做一次旋转（乘以 V^T ），接着按需要进行缩放并增加或删除维度（乘以 S ），最后在值域中做一次旋转（乘以 U ）。沿着上一讲的讨论，SVD “差不多唯一”。一个矩阵的奇异值是唯一的。当某个奇异值出现多次时，对应左、右奇异向量张成的子空间是唯一确定的，但每个子空间中可以任选标准正交基。⁵

计算矩阵 SVD 有相当不错的算法；细节会在数值分析课程中介绍。你很可能永远不需要自己实现这些算法。例如，在 Matlab 中，你真的只需要写 $[U, S, V] = \text{svd}(A)$ 就可以计算 A 的 SVD。算法运行时间是 $O(m^2n)$ 和 $O(n^2m)$ 中较小的那个，而且标准实现已经被高度优化。典型笔记本电脑计算一个 5000×5000 稠密矩阵的 SVD 应该没有困难，但对 10000×10000 矩阵可能需要一些时间。如本讲最后所说，如果你只想计算最大的 k 个奇异值及其对应奇异向量，可以显著更快地完成，大约需要 $O(kmn)$ 时间。（最后这点与本周小项目非常相关。）

5 由 SVD 得到低秩近似

如果我们想用秩 k 矩阵最佳近似矩阵 A ，应该怎么做？要是我们能把数据矩阵 A 表示成若干成分之和，并且这些成分按“重要性”排序，那就只需保留 k 个“最重要”的成分。等等，SVD 正好给出了这样的表示！回忆 SVD 把矩阵 A 表示为秩一矩阵之和（并由对应奇异值加权），一个自然想法是只保留式 (4) 右边的前 k 项。也就是说，对式 (4) 中的 A 和目标秩 k ，提出的秩 k 近似为

$$\hat{A} = \sum_{i=1}^k s_i \cdot u_i v_i^T, \quad (5)$$

其中照例假设奇异值已经排序 ($s_1 \geq s_2 \geq \dots \geq s_{\min\{m,n\}} \geq 0$)， u_i, v_i 表示第 i 个左、右奇异向量。作为 k 个秩一矩阵之和， $\hat{A}$ 显然秩至多为 k 。

下面是理解这个秩 k 近似的等价方式：

1. 计算 SVD $A = USV^T$ ，其中 U 是 $m \times m$ 正交矩阵， S 是对角元素从大到小排序的非负 $m \times n$ 对角矩阵， V^T 是 $n \times n$ 正交矩阵。
2. 只保留前 k 个右奇异向量：令 V_k^T 等于 V^T 的前 k 行（一个 $k \times n$ 矩阵）。
3. 只保留前 k 个左奇异向量：令 U_k 等于 U 的前 k 列（一个 $m \times k$ 矩阵）。
4. 只保留前 k 个奇异值：令 S_k 等于 S 的前 k 行和前 k 列（一个 $k \times k$ 矩阵），对应 A 的 k 个最大奇异值。
5. 秩 k 近似于是

$$A_k = U_k S_k V_k^T. \quad (6)$$

$$A_k = U_k S_k V_k^T, \quad U_k \in \mathbb{R}^{m \times k}, S_k \in \mathbb{R}^{k \times k}, V_k^T \in \mathbb{R}^{k \times n}$$

图 3：通过 SVD 得到低秩近似。回忆 S 只在对角线上非零，并且 S 的对角元素从大到小排序；低秩近似为 $A_k = U_k S_k V_k^T$ 。

存储式 (6) 右边的矩阵需要 $O(k(m+n))$ 空间；相比之下，存储原矩阵 A 需要 $O(mn)$ 空间。当 k 相对较小而 m, n 相对较大时（这在很多应用中都成立），这是巨大的收益。

⁵此外，总可以把第 i 个左、右奇异向量同时乘以 -1 ，从而得到另一个 SVD。

很自然地，可以把式 (6) 解释为：用 k 个“概念”（例如“数学”“音乐”“体育”）来近似原始数据 A 。 S_k 的奇异值表达这些概念的信号强度， $V^\top$ 的行和 U 的列表表达与每个概念相关的“典型行/列”（例如只喜欢音乐产品的顾客，或只被音乐型顾客喜欢的产品），而 U 的行（相应地， $V^\top$ 的列）则近似地把 A 的每一行（相应地，每一列）表示为这些“典型行”（相应地，典型列）的线性组合（并由 S_k 缩放）。

概念上，用这种方法产生低秩近似再干净不过了：我们用 SVD 重新表示 A ，得到按“重要性”排序的 A 的“成分”列表，然后只保留最重要的 k 个成分。但这个优雅计算得到的结果到底好不好？

下一个事实为这种方法提供了理由：这个低秩近似在一个自然意义下是最优的。保证使用矩阵 M 的“Frobenius 范数”，它只是把矩阵当作向量来应用 ℓ_2 范数：

$$\|M\|_F = \sqrt{\sum_{i,j} m_{ij}^2}.$$

事实 5.1 对每个 $m \times n$ 矩阵 A 、目标秩 $k \geq 1$ ，以及任意秩为 k 的 $m \times n$ 矩阵 B ，都有

$$\|A - A_k\|_F \leq \|A - B\|_F,$$

其中 A_k 是由 A 的 SVD 推出的式 (6) 中的秩 k 近似。我们不会形式化证明事实 5.1，但第 8 节会基于我们已经建立的、与其紧密相关的 PCA 方法性质，给出一个可信性论证。

备注 5.2（如何选择 k ） 在产生低秩矩阵近似时，我们一直把目标秩 k 当作参数。但 k 应该如何选择？在完美世界中， A 的奇异值会给出强烈指引：如果前几个奇异值很大，而其余都很小，那么显然应取 k 为大奇异值的数量。在不那么完美的世界中，人们会在得到有用近似的前提下尽量让 k 小；当然，“有用”是什么意思取决于具体应用。经验法则常常形如：选择 k ，使得前 k 个奇异值之和至少是其余奇异值之和的 c 倍，其中 c 是一个依赖领域的常数（比如 10）。

备注 5.3（通过截断分解实现有损压缩） 用 SVD 产生低秩矩阵近似，是有损压缩中一个有用范式的另一个例子。该范式第一步是把原始数据精确地重新表示为若干项的分解（如式 (3)）。第二步是扔掉除“最重要”项以外的所有项，得到原始数据的近似。当你能找到一种数据表示，使得大多数有趣信息集中在分解的少数几个分量中时，这个范式就很有效。合适的表示取决于数据集；虽然我们会讨论一些经验法则，但当然，足够 messy 的数据集也可能根本没有任何漂亮表示。

6 PCA 可归约为 SVD

SVD 与我们上周讨论的分解之间有一个有趣关系。回忆上一讲中，我们使用了这样一个事实： $X^\top X$ 作为对称的 $n \times n$ 矩阵，可以写成 $X^\top X = QDQ^\top$ ，其中 Q 是一个 $n \times n$ 正交矩阵， D 是一个 $n \times n$ 对角矩阵。（这里 X 是数据矩阵，每一行表示 $\mathbb{R}^n$ 中的一个数据点。）考虑 SVD $X = USV^\top$ ，以及它的存在对 $X^\top X$ 意味着什么：

$$X^\top X = (USV^\top)^\top (USV^\top) = VS^\top U^\top USV^\top = VS^\top SV^\top = VDV^\top, \quad (7)$$

其中 D 是一个对角矩阵，对角元素等于 S 的对角元素的平方（如果 $m < n$ ，那么 D 剩余的 $n - m$ 个对角元素为 0）。

回忆上一讲：如果你把 $X^T X$ 分解为 QDQ^T ，那么 Q^T 的行就是 $X^T X$ 的特征向量。因此，式 (7) 的计算表明， V^T 的行就是 $X^T X$ 的特征向量。也就是说， X 的右奇异向量与 $X^T X$ 的特征向量相同。类似地， $X^T X$ 的特征值是 X 的奇异值的平方。

因此，主成分分析 (PCA) 可以归约为计算 A 的 SVD（无需显式形成 $X^T X$ ）。回忆给定目标 k 时，PCA 的输出只是协方差矩阵 $X^T X$ 的前 k 个特征向量。 X 的 SVD USV^T 把这些特征向量直接交到你手里：它们就是 V^T 的前 k 行。这是上一讲讨论的幂迭代方法的替代方案。那么计算特征向量时哪种方法更好？没有明确答案；很多情况下，两者都能很好工作，如果性能至关重要，你会想同时试验两者。当然，当你只需要前几个特征向量时（如我们的数据可视化用例），逐个寻找 $X^T X$ 特征向量的幂迭代方法看起来是个好主意。如果你需要很多个或全部特征向量，那么 SVD 很可能是首先应该尝试的方法，因为不管你想不想要，它都会给出所有特征向量。

现在我们理解了 SVD 与 PCA 方法之间的紧密联系，回到事实 5.1：基于 SVD 的秩 k 近似是最优的（相对于 Frobenius 范数）。直观地说，这一事实成立是因为：(i) 最小化 Frobenius 范数 $\|A - B\|_F$ 等价于最小化 A 和 B 第 i 行之间平方欧氏距离的平均值（对 i 平均）；(ii) SVD 使用与 PCA 相同的向量来近似 A 的行（即 $A^T A$ 的前特征向量，也就是 A 的右奇异向量）；(iii) 根据定义，PCA 选择它的 k 个向量，使 A 的行到这些向量线性组合形成的 k 维子空间的平均平方欧氏距离最小。 $A - A_k$ 的一行对 Frobenius 范数的贡献，恰好对应这些平方欧氏距离之一。

7 PCA 与 SVD 的更多比较

PCA 和 SVD 关系密切，在数据分析圈子里，你应该准备好看到这两个术语几乎被互换使用。不过它们仍有差别。首先，PCA 指的是一种数据分析方法：一种定义“最佳”方式的选择，用少量向量的线性组合来近似一堆数据点。与此同时，SVD 是定义在所有矩阵上的通用操作。例如，说对一个矩阵 A “应用 PCA” 其实不太有意义；PCA 的输入是一组 $\mathbb{R}^n$ 中的向量 $x_1, \dots, x_m$ ，而不是一个矩阵。相反，SVD (3) 对每个矩阵 A 都有良好定义。在特殊情况下，当 A 是一个行表示数据点的矩阵时，SVD 可以解释为执行 PCA 所需的计算。（SVD 对许多其他计算任务也很有用。）

我们也可以用下面方式做一个更“苹果对苹果”的比较。把“PCA 操作”定义为：输入一个 $m \times n$ 数据矩阵 X ，并且可能输入一个参数 k ，输出协方差矩阵 $X^T X$ 的全部（或前 k 个）特征向量。“SVD 操作”输入一个 $m \times n$ 矩阵 X ，输出 U, S, V^T ，其中 V^T 的行是 $X^T X$ 的特征向量。因此，SVD 给出的信息严格多于 PCA 所需的信息，也就是它还给出矩阵 U 。

SVD 提供的额外信息 U 有用吗？在你既想理解 X 的列结构、又想理解它的行结构的应用中，答案是“有用”。为看到这一点，让我们回顾 SVD (3) 的一些解释。一方面，该分解把 X 的每一行表示为 V^T 的行的线性组合，而 US 的行给出这些线性组合的系数。也就是说，当 V^T 的行具有有趣语义时，我们可以用它们来解释 X 的行。类似地，式 (3) 的分解把 X 的列表示为 U 的列的线性组合，而系数由 SV^T 的列给出。因此，当 U 的列可解释时，该分解给了我们一种理解 X 的列的方法。

在某些应用中，我们真正关心的只是理解 X 的行，而 SVD 相比 PCA 多给出的 U 信息并不相关。在其他应用中， X 的行和列本身都很有意义。例如：

1. 假设 X 的行由顾客索引，列由产品索引，矩阵元素表示谁喜欢什么。我们有兴趣理解行；在最好情况下，右奇异向量（ V^T 的行）可以解释为“顾客类型”或“典型顾客”，SVD 把每个顾客表示为顾客类型的混合。例如，也许每个学生的购买历史都可以简单理解为“CS 顾客”“音乐顾客”和“服装顾客”的混合。在理想情况下，左奇异向量（ U 的列）可以解释为“产品类型”，其中“类型”与顾客类型相同，而 SVD 把每个产品表示为产品类型的混合（即某个产品吸引“CS 顾客”“音乐顾客”等的程度）。
2. 假设矩阵表示药物相互作用数据， X 的行由蛋白质或通路索引，列由化学物质或药物索引。我们希望分别理解蛋白质和药物本身，把它们表示为少量“基本类型”的混合。

在上面两个例子中，我们真正关心的是两组对象之间的关系：顾客与产品，或蛋白质与药物。把其中一组标为矩阵的“行”、另一组标为“列”是任意的。在这种情况下，你应该立刻想到 SVD 是一个可能帮助更好理解数据的工具。当 X 的列本身没有有趣意义时，PCA 已经提供了相关信息。

8 基于 PCA 的低秩近似（选读）

为 PCA 开发的技术也可以用来产生低秩矩阵近似，方法如下。

1. 预处理给定矩阵 A ，使其各行加总为零向量，并且可选地对每一列做归一化（像上周那样）。
2. 形成协方差矩阵 $A^T A$ 。
3. 按图 1 的记号，令 Z^T 的 k 行为 A 的前 k 个主成分，也就是 $A^T A$ 中具有最大特征值的 k 个特征向量 $v_1, v_2, \dots, v_k$ 。
4. 对 $i = 1, 2, \dots, m$ ，矩阵 Y 的第 i 行定义为 x_i 在向量 $v_1, \dots, v_k$ 上的投影

$$(\langle x_i, v_1 \rangle, \dots, \langle x_i, v_k \rangle).$$

从欧氏距离角度看，这是把 x_i 近似为 $v_1, \dots, v_k$ 的线性组合的最佳近似。⁶
上述四步当然会产生一个秩至多为 k 的矩阵

$$Y \cdot Z^T. \quad (8)$$

它与基于 SVD 的低秩近似相比如何？事实上，它们完全相同！⁷

事实 8.1 式 (8) 定义的矩阵 A_k 与式 (6) 定义的矩阵 A_k 完全相同。

我们不会证明事实 8.1，但可以暂停一下，注意它为什么可信。我们把 Z^T 定义为 A 的前 k 个主成分，也就是协方差矩阵 $A^T A$ 的前 k 个特征向量。如第 6 节所述， A 的右奇异向量（即 V^T 的行）也是 $A^T A$ 的特征向量。因此，矩阵 Z^T 和 V_k^T 是相同的，二者都等于 $A^T A$ 的前 k 个特征向量，也就是 A 的前 k 个右奇异向量。既然如此，两个 A_k 的定

⁶例如，当 $k = 2$ 时，这些值 $(\langle x_i, w_1 \rangle, \langle x_i, w_2 \rangle)$ 就是第 7 讲“欧洲地图”例子中我们绘制的值。

⁷这里假设如果要对 A 做预处理，两种情形下使用的是相同预处理。

义相同并不令人意外：式 (8) 中的矩阵 Y 和式 (6) 中的矩阵 $U_k S_k$ ，直观上都在定义 $Z^\top$ 和 $V_k^\top$ 的各行线性组合，以给出对 A 的最佳近似。在第 8 节的基于 PCA 的解法中， Y 正是这样显式定义的；而 SVD 则把相同的线性组合编码在 $U_k S_k$ 的形式中。

参考文献

- [1] Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yanzhi Li, Shean Wang, and Weizhu Chen. *LoRA: Low-Rank Adaptation of Large Language Models*. CoRR, abs/2106.09685, 2021.