

奇异值分解教程

Kirk Baker

2005 年 3 月 29 日

译者说明：本文根据用户提供的 PDF 翻译为中文。原 PDF 是粗稿，抽取文本中的部分数学符号和矩阵排版本身存在失真；本译文尽量保持原意、章节结构、例子和计算过程，并将公式改写为便于阅读的纯文本形式。

目录

1 引言	3
2 点与空间	3
3 向量	3
4 矩阵	4
4.1 矩阵记号	5
5 向量术语	6
5.1 向量长度	6
5.2 向量加法	6
5.3 标量乘法	6
5.4 内积	7
5.5 正交性	7
5.6 单位向量	7
5.7 标准正交向量	8
5.8 Gram-Schmidt 标准正交化过程	8
6 矩阵术语	10

目录	2
6.1 方阵	10
6.2 转置	10
6.3 矩阵乘法	10
6.4 单位矩阵	11
6.5 正交矩阵	12
6.6 对角矩阵	12
6.7 行列式	12
6.8 特征向量与特征值	13
7 奇异值分解	15
7.1 完整奇异值分解示例	17
7.2 降维奇异值分解示例	24
8 参考文献	27

粗稿，请自行承担使用风险。建议可发送至 kbaker@ling.osu.edu

1 引言

关于复杂主题的大多数教程，显然都是由非常聪明的人写的。他们的目标似乎是用尽可能少的篇幅讲完内容，而且假设读者已经知道的东西几乎和作者一样多。这篇教程不是那样的。它更像是一本“给我们这些普通人的宣言”。它讲的是奇异值分解的实际机制，尤其是它与自然语言处理中的某些技术之间的关系。

这篇文章的作者在开始写作之前，对奇异值分解以及其背后的数学几乎一无所知；写完之后也只是比那时多懂了一点点。因此，本文在背景铺垫上会比较长，在真正解释性的部分会短一些。不过，希望它仍然包含足够的信息，使一个以前从未听说过奇异值分解的人也能把它做出来。

2 点与空间

点只是一个数的列表。这个数的列表，也就是坐标，指定了点在空间中的位置。坐标的个数决定了这个空间的维数。

例如，我们可以用一个坐标指定尺子边缘上某个点的位置。0.5cm 和 1.2cm 这两个点的位置都可以由单个坐标精确指定。因为我们使用一个坐标来识别一个点，所以我们处理的是一维空间，也称 1-空间中的点。

平面中任意一点的位置需要一对坐标来指定；三维中的点需要三个坐标来定位。没有什么会阻止我们超出 3-空间中的点。第四维常被用来表示时间，但维度可以被选择为任何与我们试图描述的对象相关的度量单位。

一般来说，由三个以上维度表示的空间称为超空间。你也会看到 n -空间这个术语，它用来讨论不同维数的空间，例如 1-空间、2-空间，直到 n -空间。

例如，如果我想用一种简洁方式描述自己某一天吃了多少食物，就可以用 n -空间中的点来表示。假设这个空间的维度是如下食物项目：

鸡蛋葡萄香蕉鸡肉金枪鱼罐头

这里有五个类别，所以我们处理的是 5-空间中的点。因此，点 (3, 18, 2, 0.5, 1) 的解释就是“三个鸡蛋、十八颗葡萄、两根香蕉、半只鸡、一罐金枪鱼”。

3 向量

在大多数情况下，点和向量本质上是同一类东西：一串数字，对应于沿不同维度的测量值。

向量通常用上方带箭头的小写字母表示，例如 $\mathbf{x}$ 。组成向量的数字现在称为分量，分量的个数等于向量的维数。我们用向量名上的下标来指代对应位置的分量。在下面的例子中， $\mathbf{x}$ 是一个 5 维向量， $x_1 = 8$ ， $x_2 = 6$ ，等等。

$$\mathbf{x} = [8, 6, 7, 5, 3]$$

为了节省空间，向量可以等价地横向表示。例如 $\mathbf{x} = [8, 6, 7, 5, 3]$ 与上面的列向量相同。更一般地，一个 n 维向量 $\mathbf{x}$ 是 n 个数的序列，分量 x_i 表示 $\mathbf{x}$ 在第 i 个维度上的值。

4 矩阵

矩阵最容易让人联想到数据表。例如，表 1 显示了 1997 年 Fitness International 比赛中某位评委评分卡上的前 5 名选手。

表 1: 1997 Fitness International 评分卡。来源: Muscle & Fitness, 1997 年 7 月, 第 139 页。

选手	第 1 轮	第 2 轮	第 3 轮	第 4 轮	总分	名次
Carol Semple-Marzetta	17	18	5	5	45	1
Susan Curry	42	28	30	15	115	3
Monica Brant	10	10	10	21	51	2
Karen Hulse	28	5	65	39	132	5
Dale Tomita	24	26	45	21	116	4

表由行和列组成。行是与某位选手姓名对应的一串横向分数；列是与某一轮评分对应的一串纵向数字。使这个表成为矩阵的原因，是它是一个由数字构成的矩形数组。写成矩阵时，表 1 如下：

$$\begin{bmatrix} 17 & 18 & 5 & 5 & 45 & 1 \\ 42 & 28 & 30 & 15 & 115 & 3 \\ 10 & 10 & 10 & 21 & 51 & 2 \\ 28 & 5 & 65 & 39 & 132 & 5 \\ 24 & 26 & 45 & 21 & 116 & 4 \end{bmatrix}$$

矩阵的大小或维度用“行数乘列数”来表示。因此上面的矩阵是一个“5 乘 6”的矩阵，写作 5×6 矩阵。

我们可以用变量替代前面一直使用的具体数字，从而概括已经给出的描述。传统上，抽象意义上的矩阵命名为 A 。最大行数用变量 m 表示，列数称为 n 。矩阵的条目也称为元素或分量，用小写 a 表示；某个特定条目通过它所在的行索引 i 和列索引 j 引用。

例如，在上面的矩阵中，132 是第 4 行第 5 列的条目，所以另一种说法是 $a_{45} = 132$ 。更一般地，第 i 行第 j 列的元素记为 a_{ij} ，并称为 ij -条目或 ij -分量。

4.1 矩阵记号

设 m 、 n 为大于等于 1 的两个整数。设 a_{ij} 为 mn 个数，其中 $i = 1, \dots, m$ ， $j = 1, \dots, n$ 。由这些数组成的数组

$$A = \begin{bmatrix} a_{11} & \cdots & a_{1j} & \cdots & a_{1n} \\ \cdots & \cdots & \cdots & \cdots & \cdots \\ a_{i1} & \cdots & a_{ij} & \cdots & a_{in} \\ \cdots & \cdots & \cdots & \cdots & \cdots \\ a_{m1} & \cdots & a_{mj} & \cdots & a_{mn} \end{bmatrix}$$

是一个 $m \times n$ 矩阵，数 a_{ij} 是 A 的元素。数列

$$A(i) = (a_{i1}, \dots, a_{in})$$

是 A 的第 i 行；数列

$$A(j) = (a_{1j}, \dots, a_{mj})$$

是 A 的第 j 列。

正如点与向量之间的区别在实践中可能变得模糊，向量和矩阵之间的区别也会变得模糊。矩阵基本上就是向量的集合。我们可以谈论行向量或列向量。一个有 n 个分量的向量也可以看成一个 $1 \times n$ 矩阵。

例如，下面的矩阵是一个词项-文档矩阵，它显示某个词在一些虚构文档中出现的次数。

表 2: 一些虚构文档的词项-文档矩阵。

词项	文档 1	文档 2	文档 3
abbey	2	3	5
spinning	1	0	1
soil	3	4	1
stunned	2	1	3
wrath	1	1	4

对这类矩阵的典型描述可能类似于“高维向量空间模型”。如果我们谈论表示文档的列向量，那么维度就是词；如果我们谈论表示词的行向量，那么维度就是文档。“高维”意味

着这样的维度很多。因此，“超空间文档表示”的意思是：一个文档被表示为一个向量，其分量以某种方式对应于文档中的词，而且词的数量很多。这等价于说“一个文档被表示为 n 维空间中的一个点”。

5 向量术语

5.1 向量长度

向量长度的求法是：将每个分量平方，把所有平方值相加，然后对总和开平方。如果 v 是一个向量，它的长度记作 $|v|$ 。更简洁地说：

$$|v| = \sqrt{\sum_{i=1}^n x_i^2}$$

例如，如果 $v = [4, 11, 8, 10]$ ，则

$$|v| = \sqrt{4^2 + 11^2 + 8^2 + 10^2} = \sqrt{301} = 17.35$$

5.2 向量加法

两个向量相加，意思是将 v_1 中的每个分量与 v_2 中对应位置的分量相加，从而得到一个新向量。例如：

$$\begin{aligned} [3, 2, 1, -2] + [2, -1, 4, 1] \\ &= [(3 + 2), (2 - 1), (1 + 4), (-2 + 1)] \\ &= [5, 1, 5, -1] \end{aligned}$$

更一般地，如果 $A = [a_1, a_2, \dots, a_n]$ ， $B = [b_1, b_2, \dots, b_n]$ ，那么

$$A + B = [a_1 + b_1, a_2 + b_2, \dots, a_n + b_n]$$

5.3 标量乘法

用一个标量，也就是一个实数，乘以一个向量，意思是用这个实数乘以向量的每个分量，从而得到一个新向量。例如，如果 $v = [3, 6, 8, 4]$ ，那么

$$1.5 \cdot v = 1.5 \cdot [3, 6, 8, 4] = [4.5, 9, 12, 6]$$

更一般地，标量乘法意味着：如果 d 是实数， v 是向量 $[v_1, v_2, \dots, v_n]$ ，那么

$$d \cdot v = [dv_1, dv_2, \dots, dv_n]$$

5.4 内积

两个向量的内积也称为点积或标量积，它定义了向量之间的一种乘法。求法是：把 v_1 中的每个分量与 v_2 中相同位置的分量相乘，再把这些乘积全部相加，得到一个标量值。内积只对维数相同的向量有定义。

两个向量的内积记作 (v_1, v_2) 或 $v_1 \cdot v_2$ 。因此：

$$(x, y) = x \cdot y = \sum_{i=1}^n x_i y_i$$

例如，如果 $x = [1, 6, 7, 4]$ ， $y = [3, 2, 8, 3]$ ，那么

$$x \cdot y = 1(3) + 6(2) + 7(8) + 3(4) = 83$$

5.5 正交性

如果两个向量的内积等于零，则称它们相互正交。在二维空间中，这等价于说两个向量互相垂直，也就是说它们之间唯一的夹角是 90 度。例如，向量 $[2, 1, -2, 4]$ 和 $[3, -6, 4, 2]$ 是正交的，因为：

$$\begin{aligned} [2, 1, -2, 4] \cdot [3, -6, 4, 2] \\ &= 2(3) + 1(-6) + (-2)(4) + 4(2) \\ &= 0 \end{aligned}$$

5.6 单位向量

单位向量是长度为 1 的向量。任何初始长度大于 0 的向量都可以通过将每个分量除以该向量的长度来归一化。例如，如果 $v = [2, 4, 1, 2]$ ，那么：

$$|v| = \sqrt{2^2 + 4^2 + 1^2 + 2^2} = \sqrt{25} = 5$$

于是 $u = [2/5, 4/5, 1/5, 2/5]$ 是一个单位向量，因为：

$$\begin{aligned} |u| &= \sqrt{(2/5)^2 + (4/5)^2 + (1/5)^2 + (2/5)^2} \\ &= \sqrt{25/25} \\ &= 1 \end{aligned}$$

5.7 标准正交向量

长度为 1 且彼此正交的向量称为标准正交向量。例如：

$$\begin{aligned} u &= \left[\frac{2}{5}, \frac{1}{5}, \frac{-2}{5}, \frac{4}{5} \right] \\ v &= \left[\frac{3}{\sqrt{65}}, \frac{-6}{\sqrt{65}}, \frac{4}{\sqrt{65}}, \frac{2}{\sqrt{65}} \right] \end{aligned}$$

它们是标准正交的，因为：

$$\begin{aligned} |u| &= \sqrt{(2/5)^2 + (1/5)^2 + (-2/5)^2 + (4/5)^2} = 1 \\ |v| &= \sqrt{(3/\sqrt{65})^2 + (-6/\sqrt{65})^2 + (4/\sqrt{65})^2 + (2/\sqrt{65})^2} = 1 \\ u \cdot v &= 6/(5\sqrt{65}) - 6/(5\sqrt{65}) - 8/(5\sqrt{65}) + 8/(5\sqrt{65}) = 0 \end{aligned}$$

5.8 Gram-Schmidt 标准正交化过程

Gram-Schmidt 标准正交化过程是一种方法，用来把一组向量转换成一组标准正交向量。它的基本做法是：先将正在考虑的第一个向量归一化，然后迭代地把剩余向量重写为“它们自身减去若干个已经归一化向量的倍数”。

例如，要把矩阵 A 的列向量

$$A = \begin{bmatrix} 1 & 2 & 1 \\ 0 & 2 & 0 \\ 2 & 3 & 1 \\ 1 & 1 & 0 \end{bmatrix}$$

转换成标准正交列向量，先归一化 $v_1 = [1, 0, 2, 1]$ ：

$$u_1 = \left[\frac{1}{\sqrt{6}}, 0, \frac{2}{\sqrt{6}}, \frac{1}{\sqrt{6}} \right]$$

接着令

$$w_2 = v_2 - (u_1 \cdot v_2)u_1$$

代入 $v_2 = [2, 2, 3, 1]$, 可得:

$$\begin{aligned} w_2 &= [2, 2, 3, 1] - (9/\sqrt{6}) \left[\frac{1}{\sqrt{6}}, 0, \frac{2}{\sqrt{6}}, \frac{1}{\sqrt{6}} \right] \\ &= [2, 2, 3, 1] - \left[\frac{3}{2}, 0, 3, \frac{3}{2} \right] \\ &= \left[\frac{1}{2}, 2, 0, \frac{-1}{2} \right] \end{aligned}$$

归一化 w_2 得到:

$$u_2 = \left[\frac{\sqrt{2}}{6}, \frac{2\sqrt{2}}{3}, 0, \frac{-\sqrt{2}}{6} \right]$$

现在用 u_1 和 u_2 计算 u_3 。令:

$$\begin{aligned} w_3 &= v_3 - (u_1 \cdot v_3)u_1 - (u_2 \cdot v_3)u_2 \\ &= \left[\frac{4}{9}, \frac{-2}{9}, 0, \frac{-4}{9} \right] \end{aligned}$$

归一化 w_3 得到:

$$u_3 = \left[\frac{2}{3}, \frac{-1}{3}, 0, \frac{-2}{3} \right]$$

更一般地, 如果我们已经有一组标准正交向量 $u_1, \dots, u_{k-1}$, 那么 w_k 可表示为:

$$w_k = v_k - \sum_{i=1}^{k-1} (u_i \cdot v_k) u_i$$

6 矩阵术语

6.1 方阵

如果一个矩阵的行数和列数相同，则称其为方阵。为了表示一个有 n 行 n 列的方阵的大小，可以称它为 n 阶方阵。例如，下面的矩阵是 3 阶方阵：

$$A = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{bmatrix}$$

6.2 转置

矩阵的转置通过把矩阵的行转换成列来得到；也就是说，第 1 行变成第 1 列，第 2 行变成第 2 列，依此类推。矩阵转置用上标 T 表示，例如矩阵 A 的转置是 A^T 。

例如，如果

$$A = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix}$$

那么它的转置是：

$$A^T = \begin{bmatrix} 1 & 4 \\ 2 & 5 \\ 3 & 6 \end{bmatrix}$$

6.3 矩阵乘法

只有当第二个矩阵的行数等于第一个矩阵的列数时，两个矩阵才可以相乘。结果矩阵的行数与第一个矩阵相同，列数与第二个矩阵相同。换句话说，如果 A 是一个 $m \times n$ 矩阵， B 是一个 $n \times s$ 矩阵，那么乘积 AB 是一个 $m \times s$ 矩阵。

AB 的坐标由 A 的每一行与 B 的每一列的内积决定。也就是说，如果 $A_1, \dots, A_m$ 是矩阵 A 的行向量， $B_1, \dots, B_s$ 是 B 的列向量，那么 AB 中的元素 ab_{ik} 等于 $A_i \cdot B_k$ 。下面的例子说明了这一点。

$$A = \begin{bmatrix} 2 & 1 & 4 \\ 1 & 5 & 2 \end{bmatrix}$$

$$B = \begin{bmatrix} 3 & 2 \\ -1 & 4 \\ 1 & 2 \end{bmatrix}$$

$$AB = \begin{bmatrix} 9 & 16 \\ 0 & 26 \end{bmatrix}$$

因为:

$$ab_{11} = [2, 1, 4] \cdot [3, -1, 1] = 2(3) + 1(-1) + 4(1) = 9$$

$$ab_{12} = [2, 1, 4] \cdot [2, 4, 2] = 2(2) + 1(4) + 4(2) = 16$$

$$ab_{21} = [1, 5, 2] \cdot [3, -1, 1] = 1(3) + 5(-1) + 2(1) = 0$$

$$ab_{22} = [1, 5, 2] \cdot [2, 4, 2] = 1(2) + 5(4) + 2(2) = 26$$

6.4 单位矩阵

单位矩阵是一个方阵，其主对角线上的条目全为 1，其他条目全为 0。主对角线是所有满足 $i = j$ 的条目 a_{ij} ，也就是 $a_{11}, a_{22}, \dots, a_{mm}$ 。n 阶单位矩阵可记为 I_n 、 $I_{\{n \times n\}}$ ，或简单地记作 I 。

单位矩阵在矩阵乘法中的行为类似于普通乘法中的数字 1，这意味着 $AI = A$ 。如下例所示：

$$A = \begin{bmatrix} 2 & 4 & 6 \\ 1 & 3 & 5 \end{bmatrix}$$

$$I = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

$$AI = \begin{bmatrix} 2 & 4 & 6 \\ 1 & 3 & 5 \end{bmatrix}$$

逐项计算可得：

$$a_{i11} = [2, 4, 6] \cdot [1, 0, 0] = 2$$

$$a_{i12} = [2, 4, 6] \cdot [0, 1, 0] = 4$$

$$a_{i13} = [2, 4, 6] \cdot [0, 0, 1] = 6$$

$$a_{i21} = [1, 3, 5] \cdot [1, 0, 0] = 1$$

$$a_{i22} = [1, 3, 5] \cdot [0, 1, 0] = 3$$

$$a_{i23} = [1, 3, 5] \cdot [0, 0, 1] = 5$$

6.5 正交矩阵

如果 $A^T A = A A^T = I$ ，则矩阵 A 是正交矩阵。例如：

$$A = \begin{bmatrix} 1 & 0 & 0 \\ 0 & \frac{3}{5} & \frac{-4}{5} \\ 0 & \frac{4}{5} & \frac{3}{5} \end{bmatrix}$$

它是正交的，因为：

$$A^T A = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

6.6 对角矩阵

对角矩阵 A 是这样一种矩阵：当 i 不等于 j 时，所有条目 a_{ij} 都为 0。换句话说，唯一的非零值沿着从左上角到右下角的主对角线排列：

$$A = \begin{bmatrix} a_{11} & 0 & \cdots & 0 \\ 0 & a_{22} & \cdots & 0 \\ \cdots & \cdots & \cdots & \cdots \\ 0 & 0 & \cdots & a_{mm} \end{bmatrix}$$

6.7 行列式

行列式是定义在方阵上的一个函数，它把一个方阵化约为一个单独的数。矩阵 A 的行列式记作 $|A|$ 或 $\det(A)$ 。

如果 A 只包含一个元素 a ，那么 $|A| = a$ ；换句话说，如果 $A = [6]$ ，则 $|A| = 6$ 。如果 A 是一个 2×2 矩阵：

$$A = \begin{bmatrix} a & b \\ c & d \end{bmatrix}$$

那么：

$$|A| = ad - bc$$

例如，矩阵

$$A = \begin{bmatrix} 4 & 1 \\ 1 & 2 \end{bmatrix}$$

的行列式为：

$$|A| = 4(2) - 1(1) = 7$$

对于 $n > 2$ 的 n 阶方阵，可以通过递归地删除行和列来构造越来越小的矩阵，直到它们全都成为 2×2 矩阵，然后应用前面的定义来求行列式。有一些技巧可以更高效地完成这件事，但最基本的方法称为按行展开。下面以一个 3×3 矩阵为例说明。

这里沿第 1 行展开，也就是说，删除第 1 行，并依次删除第 1 列、第 2 列和第 3 列，以创建三个 2×2 矩阵。每个较小矩阵的行列式都乘以被删除行和列交点处的条目。展开式对连续的行列式交替加减。

原例中的计算可概括为：

$$\begin{aligned} |A| &= -1(6 \cdot 8 - 4 \cdot (-2)) - 4(2 \cdot 8 - 4 \cdot 3) + 3(2 \cdot (-2) - 3 \cdot 6) \\ &= -56 - 16 - 66 \\ &= -138 \end{aligned}$$

一个 4×4 矩阵的行列式可以通过沿第 1 行展开，交替加减 4 个 3×3 行列式来求；这些 3×3 行列式又可以继续展开成一系列 2×2 行列式，并按上面的方式化约。这个过程可以用于求任意大小方阵的行列式。

6.8 特征向量与特征值

特征向量是满足下列方程的非零向量：

$$Av = \lambda v$$

其中 A 是方阵， λ 是标量， v 是特征向量。 λ 称为特征值。特征值和特征向量也分别称为 characteristic roots 和 characteristic vectors，或 latent roots 和 latent vectors。

你可以把矩阵看作线性方程组，通过求解组成特征向量分量的变量值来找到特征值和特征向量。例如，求矩阵

$$A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$$

的特征值和对应的特征向量，意味着应用上面的公式：

$$Av = \lambda v$$

即：

$$\begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} [x_1, x_2]^T = \lambda [x_1, x_2]^T$$

这等价于方程组：

$$\begin{aligned} 2x_1 + x_2 &= \lambda x_1 \\ x_1 + 2x_2 &= \lambda x_2 \end{aligned}$$

可重排为：

$$\begin{aligned} (2 - \lambda)x_1 + x_2 &= 0 \\ x_1 + (2 - \lambda)x_2 &= 0 \end{aligned}$$

该方程组存在非零向量 $[x_1, x_2]$ 的充要条件，是其系数矩阵的行列式等于 0：

$$\begin{vmatrix} (2 - \lambda) & 1 \\ 1 & (2 - \lambda) \end{vmatrix} = 0$$

因此：

$$\begin{aligned} (2 - \lambda)(2 - \lambda) - 1 \cdot 1 &= 0 \\ \lambda^2 - 4\lambda + 3 &= 0 \end{aligned}$$

$$(\lambda - 3)(\lambda - 1) = 0$$

有两个 λ 值满足最后一个方程。因此，原矩阵 A 有两个特征值：

$$\lambda_1 = 3, \lambda_2 = 1$$

把 λ 代回前面的方程并求解 x_1 和 x_2 ，就可以找到与这些特征值对应的特征向量。为了求 $\lambda = 3$ 对应的特征向量，从

$$(2 - \lambda)x_1 + x_2 = 0$$

开始，代入得到：

$$(2 - 3)x_1 + x_2 = 0$$

化简并重排得：

$$x_1 = x_2$$

满足这个方程的 x_1 值有无穷多个；唯一限制是特征向量中的分量不能全为零。因此，如果 $x_1 = 1$ ，那么 $x_2 = 1$ ，与 $\lambda = 3$ 对应的一个特征向量是 $[1, 1]$ 。

求 $\lambda = 1$ 的特征向量也一样：

$$(2 - 1)x_1 + x_2 = 0$$

$$x_1 = -x_2$$

所以 $\lambda = 1$ 的一个特征向量是 $[1, -1]$ 。

7 奇异值分解

奇异值分解（SVD）可以从三个彼此兼容的角度来看。一方面，我们可以把它看成一种方法，用于把相关变量转换成一组不相关变量，从而更好地揭示原始数据项之间的各种关系。与此同时，SVD 也是一种识别并排序维度的方法：它找出数据点在哪些维度上表现出最多变化。

这又与第三种看法联系在一起：一旦我们识别出变化最多的方向，就可以用较少的维度找到对原始数据点的最佳近似。因此，SVD 可以被看成一种数据降维方法。

为了说明这些想法，请考虑原文图 1 中的二维数据点。穿过这些点的回归线展示了用一个一维对象，也就是一条直线，去近似原始数据时的最佳近似。所谓最佳，是指这条线使每个原始点到该线的距离最小。




图 1: 最佳拟合回归线将数据从二维降为一维。

如果我们从每个点向回归线画一条垂线，并把这些垂线与回归线的交点作为原始数据点的近似，那么我们就得到了原始数据的一个降维表示，它尽可能多地捕捉了原始变化。

请注意，原文图 2 还显示了第二条回归线，它与第一条回归线垂直。这条线沿原始数据集的第二个维度尽可能多地捕捉变化。它对原始数据的近似效果较差，因为它对应的是一个从一开始就表现出较少变化的维度。

可以使用这些回归线生成一组不相关的数据点，从而显示出原始数据中初看未必可见的子群结构。

这些就是 SVD 背后的基本思想：取一组高维、高变化性的数据点，把它们降到一个较低维的空间中，使原始数据的子结构更清晰地显现出来，并且按照变化量从最大到最小排序。

使 SVD 对自然语言处理应用有用的一点是：你可以直接忽略低于某个阈值的变化，从而大幅压缩数据，同时仍然确信主要的相关关系已经被保留下来。




图 2: 沿第二维的回归线捕捉到的原始数据变化较少。

7.1 完整奇异值分解示例

SVD 基于线性代数中的一个定理。该定理说明，一个矩形矩阵 A 可以分解为三个矩阵的乘积：一个正交矩阵 U 、一个对角矩阵 S ，以及一个正交矩阵 V 的转置。这个定理通常写作：

$$A_{m \times n} = U_{m \times m} S_{m \times n} V_{n \times n}^T$$

其中：

$$U^T U = I$$

$$V^T V = I$$

U 的列是 $A A^T$ 的标准正交特征向量 V 的列是 $A^T A$ 的标准正交特征向量 S 是一个对角矩阵，其中包含来自 U 或 V 的特征值平方根，并按降序排列

下面的例子只是把这个定义应用到一个小矩阵上，以计算它的 SVD。下一节会尝试解释 SVD 在文档分类中的应用。

从矩阵开始：

$$A = \begin{bmatrix} 3 & 1 & 1 \\ -1 & 3 & 1 \end{bmatrix}$$

为了找到 U ，我们必须先从 $A A^T$ 开始。 A 的转置是：

$$A^T = \begin{bmatrix} 3 & -1 \\ 1 & 3 \\ 1 & 1 \end{bmatrix}$$

所以：

$$AA^T = \begin{bmatrix} 3 & 1 & 1 \\ -1 & 3 & 1 \end{bmatrix}$$

$$\begin{bmatrix} 3 & -1 \\ 1 & 3 \\ 1 & 1 \end{bmatrix}$$

$$= \begin{bmatrix} 11 & 1 \\ 1 & 11 \end{bmatrix}$$

接着，我们必须求 AA^T 的特征值和对应特征向量。我们知道特征向量由方程 $AA^T v = \lambda v$ 定义，把它应用到 AA^T 得到：

$$\begin{bmatrix} 11 & 1 \\ 1 & 11 \end{bmatrix} [x_1, x_2]^T$$

$$= \lambda [x_1, x_2]^T$$

这可写成方程组：

$$11x_1 + x_2 = \lambda x_1$$

$$x_1 + 11x_2 = \lambda x_2$$

重排得到：

$$(11 - \lambda)x_1 + x_2 = 0$$

$$x_1 + (11 - \lambda)x_2 = 0$$

通过令系数矩阵行列式为零来解 λ ：

$$\begin{vmatrix} (11 - \lambda) & 1 \\ 1 & (11 - \lambda) \end{vmatrix} = 0$$

展开为:

$$\begin{aligned}(11 - \lambda)(11 - \lambda) - 1 \cdot 1 &= 0 \\ (\lambda - 10)(\lambda - 12) &= 0\end{aligned}$$

因此有两个特征值:

$$\lambda = 10, \lambda = 12$$

把 lambda 代回原方程得到特征向量。对 lambda = 10:

$$\begin{aligned}(11 - 10)x_1 + x_2 &= 0 \\ x_1 &= -x_2\end{aligned}$$

满足它的值很多, 所以选择 $x_1 = 1$, $x_2 = -1$, 因为这些数小且便于计算。因此, 对应 lambda = 10 的特征向量是 $[1, -1]$ 。

对 lambda = 12:

$$\begin{aligned}(11 - 12)x_1 + x_2 &= 0 \\ x_1 &= x_2\end{aligned}$$

同理取 $x_1 = 1$, $x_2 = 1$ 。于是 lambda = 12 的特征向量是 $[1, 1]$ 。

这些特征向量按照对应特征值的大小作为矩阵中的列向量。也就是说, 最大特征值对应的特征向量是第 1 列, 次大特征值对应的特征向量是第 2 列, 如此继续, 直到最小特征值对应的特征向量成为矩阵的最后一列。在下面的矩阵中, lambda = 12 的特征向量是第 1 列, lambda = 10 的特征向量是第 2 列:

$$\begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}$$

最后, 我们必须把这个矩阵转换成正交矩阵。这通过对列向量应用 Gram-Schmidt 标准正交化过程完成。先归一化 v_1 :

$$\begin{aligned}u_1 &= v_1 / |v_1| \\ &= [1, 1] / \sqrt{1^2 + 1^2}\end{aligned}$$

$$= \left[\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}} \right]$$

计算:

$$\begin{aligned} w_2 &= v_2 - (u_1 \cdot v_2)u_1 \\ &= [1, -1] - \left(\left[\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}} \right] \cdot [1, -1] \right) \left[\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}} \right] \\ &= [1, -1] \end{aligned}$$

并归一化:

$$\begin{aligned} u_2 &= w_2 / |w_2| \\ &= \left[\frac{1}{\sqrt{2}}, \frac{-1}{\sqrt{2}} \right] \end{aligned}$$

得到:

$$U = \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{-1}{\sqrt{2}} \end{bmatrix}$$

V 的计算类似。V 基于 $A^T A$, 因此:

$$A^T A = \begin{bmatrix} 10 & 0 & 2 \\ 0 & 10 & 4 \\ 2 & 4 & 2 \end{bmatrix}$$

通过

$$\begin{aligned} &\begin{bmatrix} 10 & 0 & 2 \\ 0 & 10 & 4 \\ 2 & 4 & 2 \end{bmatrix} [x_1, x_2, x_3]^T \\ &= \lambda [x_1, x_2, x_3]^T \end{aligned}$$

求 $A^T A$ 的特征值。这代表方程组:

$$10x_1 + 2x_3 = \lambda x_1$$

$$\begin{aligned}10x_2 + 4x_3 &= \lambda x_2 \\2x_1 + 4x_2 + 2x_3 &= \lambda x_3\end{aligned}$$

重写为:

$$\begin{aligned}(10 - \lambda)x_1 + 2x_3 &= 0 \\(10 - \lambda)x_2 + 4x_3 &= 0 \\2x_1 + 4x_2 + (2 - \lambda)x_3 &= 0\end{aligned}$$

令行列式为零:

$$\begin{vmatrix} (10 - \lambda) & 0 & 2 \\ 0 & (10 - \lambda) & 4 \\ 2 & 4 & (2 - \lambda) \end{vmatrix} = 0$$

可化为:

$$\lambda(\lambda - 10)(\lambda - 12) = 0$$

所以 $A^T A$ 的特征值是:

$$\lambda = 0, \lambda = 10, \lambda = 12$$

把 λ 代回原方程求对应特征向量。对 $\lambda = 12$:

$$\begin{aligned}(10 - 12)x_1 + 2x_3 &= -2x_1 + 2x_3 = 0 \\x_1 &= 1, x_3 = 1\end{aligned}$$

$$\begin{aligned}(10 - 12)x_2 + 4x_3 &= -2x_2 + 4x_3 = 0 \\x_2 &= 2x_3 = 2\end{aligned}$$

所以对 $\lambda = 12$, 有 $v_1 = [1, 2, 1]^T$ 。

对 $\lambda = 10$:

$$(10 - 10)x_1 + 2x_3 = 2x_3 = 0$$

$$x_3 = 0$$

$$2x_1 + 4x_2 = 0$$

$$x_1 = -2x_2$$

取 $x_1 = 2$, $x_2 = -1$, 于是对 $\lambda = 10$, 有 $v_2 = [2, -1, 0]$ 。

对 $\lambda = 0$:

$$10x_1 + 2x_3 = 0$$

$$x_3 = -5x_1$$

$$10x_2 + 4x_3 = 0$$

若 $x_1 = 1$, 则 $x_3 = -5$, $x_2 = 2$

所以对 $\lambda = 0$, 有 $v_3 = [1, 2, -5]$ 。

按照特征值大小, 把 v_1 、 v_2 、 v_3 作为列向量排列成矩阵:

$$\begin{bmatrix} 1 & 2 & 1 \\ 2 & -1 & 2 \\ 1 & 0 & -5 \end{bmatrix}$$

并用 Gram-Schmidt 标准正交化过程把它转换成标准正交矩阵:

$$u_1 = v_1/|v_1| = \left[\frac{1}{\sqrt{6}}, \frac{2}{\sqrt{6}}, \frac{1}{\sqrt{6}} \right]$$

$$u_2 = \left[\frac{2}{\sqrt{5}}, \frac{-1}{\sqrt{5}}, 0 \right]$$

$$u_3 = \left[\frac{1}{\sqrt{30}}, \frac{2}{\sqrt{30}}, \frac{-5}{\sqrt{30}} \right]$$

于是：

$$V = \begin{bmatrix} \frac{1}{\sqrt{6}} & \frac{2}{\sqrt{5}} & \frac{1}{\sqrt{30}} \\ \frac{2}{\sqrt{6}} & \frac{-1}{\sqrt{5}} & \frac{2}{\sqrt{30}} \\ \frac{1}{\sqrt{6}} & 0 & \frac{-5}{\sqrt{30}} \end{bmatrix}$$

我们真正需要的是它的转置：

$$V^T = \begin{bmatrix} \frac{1}{\sqrt{6}} & \frac{2}{\sqrt{6}} & \frac{1}{\sqrt{6}} \\ \frac{2}{\sqrt{5}} & \frac{-1}{\sqrt{5}} & 0 \\ \frac{1}{\sqrt{30}} & \frac{2}{\sqrt{30}} & \frac{-5}{\sqrt{30}} \end{bmatrix}$$

对于 S，我们取非零特征值的平方根，并把它们按从大到小的顺序填入对角线：最大的放在 s11，次大的放在 s22，如此继续。U 和 V 的非零特征值总是相同的，所以从哪一个取都无所谓。

因为这里做的是完整 SVD，而不是下一节的降维 SVD，所以必须给 S 添加一个零列向量，使它具有适当的维度，以便 U、S 和 V 之间可以相乘。S 中的对角线条目称为 A 的奇异值；U 的列称为左奇异向量；V 的列称为右奇异向量。

$$S = \begin{bmatrix} \sqrt{12} & 0 & 0 \\ 0 & \sqrt{10} & 0 \end{bmatrix}$$

现在所有拼图块都齐了：

$$A = USV^T$$

即：

$$\begin{aligned} & \begin{bmatrix} 3 & 1 & 1 \\ -1 & 3 & 1 \end{bmatrix} \\ &= \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{-1}{\sqrt{2}} \end{bmatrix} \\ & \begin{bmatrix} \sqrt{12} & 0 & 0 \\ 0 & \sqrt{10} & 0 \end{bmatrix} \\ & \begin{bmatrix} \frac{1}{\sqrt{6}} & \frac{2}{\sqrt{6}} & \frac{1}{\sqrt{6}} \\ \frac{2}{\sqrt{5}} & \frac{-1}{\sqrt{5}} & 0 \\ \frac{1}{\sqrt{30}} & \frac{2}{\sqrt{30}} & \frac{-5}{\sqrt{30}} \end{bmatrix} \end{aligned}$$

7.2 降维奇异值分解示例

降维奇异值分解是某类文档检索和词语相似度方法背后的数学技术。这些方法有时称为潜在语义索引 (Latent Semantic Indexing), 也称为潜在语义分析 (Latent Semantic Analysis)。

把 SVD 用于这些任务的核心洞见是: 它把原始数据, 通常是某种形式的词项-文档矩阵, 分解成线性无关的分量。从某种意义上说, 这些分量从原始数据中嘈杂的相关关系抽象出来, 得到一组值; 这些值在每个维度上独立地最佳近似数据集的底层结构。

因为这些分量中的大多数都很小, 所以可以忽略它们, 从而得到一个数据近似, 其维度显著少于原始数据。SVD 还有一个额外好处: 在降维过程中, 具有共同子结构的项目会变得彼此更相似, 而一开始就不相似的项目也可能变得更加不相似。实际来说, 这意味着关于某个特定主题的文档会变得更相似, 即使完全相同的词并没有出现在所有文档中。

正如我们已经看到的, SVD 从一个矩阵开始。因此, 我们把下面的词项-文档矩阵作为下一个例子的起点:

$$A = \begin{bmatrix} 2 & 0 & 8 & 6 & 0 \\ 1 & 6 & 0 & 1 & 7 \\ 5 & 0 & 7 & 4 & 0 \\ 7 & 0 & 8 & 5 & 0 \\ 0 & 10 & 0 & 0 & 7 \end{bmatrix}$$

记住, 为了计算矩阵 A 的 SVD, 我们想要三个矩阵的乘积:

$$A = USV^T$$

其中 U 和 V 是标准正交的, S 是对角矩阵。 U 的列向量来自 AA^T 的标准正交特征向量, 并按照对应特征值从大到小排列。

注意:

$$AA^T = \begin{bmatrix} 104 & 8 & 90 & 108 & 0 \\ 8 & 87 & 9 & 12 & 109 \\ 90 & 9 & 90 & 111 & 0 \\ 108 & 12 & 111 & 138 & 0 \\ 0 & 109 & 0 & 0 & 149 \end{bmatrix}$$

这是一个由所有词项之间的点积组成的矩阵, 因此它是一种词项在所有文档中分布情况的离散度矩阵。 AA^T 的奇异值 (这里原文称 eigenvalues) 是:

$$\lambda = 321.07, 230.17, 12.70, 3.94, 0.12$$

这些值用于计算并排序 U 中对应的标准正交奇异向量:

$$U = \begin{bmatrix} -0.54 & -0.07 & 0.82 & 0.11 & -0.12 \\ -0.10 & 0.59 & -0.11 & -0.79 & -0.06 \\ -0.53 & -0.06 & -0.21 & -0.12 & 0.81 \\ -0.65 & -0.07 & -0.51 & 0.06 & -0.56 \\ -0.06 & 0.80 & 0.09 & 0.59 & 0.04 \end{bmatrix}$$

这本质上给出了一个矩阵, 其中词被表示为行向量, 而这些行向量包含线性无关的分量。这些文档中的某些词共现模式, 可以通过 U 中系数的符号看出来。

例如, 第一列向量中的符号全为负, 表示词和文档的一般共现。 U 的第二列向量中可见两个组: car 和 wheel 的系数为负, 而 doctor、nurse 和 hospital 都为正; 这表示一个分组, 其中 wheel 只与 car 共现。

第三个维度表示一个分组, 其中 car、nurse 和 hospital 只彼此共同出现。第四个维度指出一种模式: nurse 和 hospital 在没有 wheel 的情况下出现。第五个维度表示一个分组: doctor 和 hospital 在没有 wheel 的情况下出现。

计算 V^T 的过程类似。因为它的值来自 $A^T A$ 的标准正交奇异向量, 并按照对应奇异值从大到小排列, 所以有:

$$A^T A = \begin{bmatrix} 79 & 6 & 107 & 68 & 7 \\ 6 & 136 & 0 & 6 & 112 \\ 107 & 0 & 177 & 116 & 0 \\ 68 & 6 & 116 & 78 & 7 \\ 7 & 112 & 0 & 7 & 98 \end{bmatrix}$$

这个矩阵包含所有文档之间的点积。应用 Gram-Schmidt 标准正交化过程并取转置, 得到:

$$V^T = \begin{bmatrix} -0.46 & -0.02 & -0.87 & 0.00 & -0.17 \\ 0.07 & 0.76 & -0.06 & 0.60 & 0.23 \\ 0.74 & -0.10 & 0.28 & -0.22 & 0.56 \\ 0.48 & 0.03 & 0.40 & -0.33 & -0.70 \\ -0.07 & 0.64 & -0.04 & -0.69 & 0.32 \end{bmatrix}$$

S 包含按从大到小排列在对角线上的奇异值平方根。这些值表示线性无关分量沿每个维度的方差。为了说明降维对这个数据集的影响, 我们把 S 限制为前三个奇异值:

$$S = \begin{bmatrix} 17.92 & 0 & 0 \\ 0 & 15.17 & 0 \\ 0 & 0 & 3.56 \end{bmatrix}$$

为了让矩阵乘法能够进行，必须删除 U 中对应的列向量以及 V^T 中对应的行向量，从而用 3 个维度而不是原来的 5 个维度得到 A 的一个近似。结果如下：

$$\hat{A} = \begin{bmatrix} 0.54 & -0.07 & 0.82 \\ 0.10 & 0.59 & 0.11 \\ 0.53 & -0.06 & -0.21 \\ 0.65 & -0.07 & -0.51 \\ 0.06 & 0.80 & 0.09 \end{bmatrix}$$

$$\begin{bmatrix} 17.92 & 0 & 0 \\ 0 & 15.17 & 0 \\ 0 & 0 & 3.56 \end{bmatrix}$$

$$\begin{bmatrix} 0.46 & -0.02 & 0.87 & 0.00 & -0.17 \\ 0.07 & 0.76 & -0.06 & 0.60 & 0.23 \\ 0.74 & -0.10 & 0.28 & -0.22 & 0.56 \end{bmatrix}$$

计算结果为：

$$\hat{A} = \begin{bmatrix} 2.29 & -0.66 & 9.33 & 1.25 & -3.09 \\ 1.77 & 6.76 & -0.90 & 5.50 & 2.13 \\ 4.86 & -0.96 & 8.01 & 0.38 & -0.97 \\ 6.62 & -1.23 & 9.58 & 0.24 & -0.71 \\ 1.14 & 9.19 & -0.33 & 7.19 & 3.13 \end{bmatrix}$$

不过在实践中，目的并不是实际重构原始矩阵，而是使用降维表示来识别相似的词和文档。现在，文档由 V 中的行向量表示；文档相似度通过比较矩阵 $V S$ 中的行来获得。注意，文档被表示为行向量，是因为我们处理的是 V ，而不是 V^T 。词由 U 中的行向量表示；词相似度可以通过计算 $U S$ 中的行相似度来度量。

前面我提到过，在降维过程中，SVD 会让相似项目看起来更相似，让不同项目看起来更不同。这可以通过查看上面 U 和 V 的降维版本中的向量来解释。

我们知道，这些向量包含按解释原始数据中变化量从大到小排列的分量。通过删除那些不表现出有意义变化的维度对应的元素，我们实际上消除了词向量表示中的噪声。现在，词向量更短，并且只包含那些解释原始数据集中词之间最显著相关关系的元素。被删除的元素原本会沿着意义可疑的维度引入潜在相似性，从而稀释这些主要相关关系。

8 参考文献

Deerwester, S., Dumais, S., Landauer, T., Furnas, G. and Harshman, R. (1990). "Indexing by Latent Semantic Analysis". *Journal of the American Society of Information Science* 41(6):391-407.

Ientilucci, E.J., (2003). "Using the Singular Value Decomposition". <http://www.cis.rit.edu/~ejipci/re>

Jackson, J. E. (1991). *A User's Guide to Principal Components Analysis*. John Wiley & Sons, NY.

Manning, C. and Schutze, H. (1999). *Foundations of Statistical Natural Language Processing*. MIT Press, Cambridge, MA.

Marcus, M. and Minc, H. (1968). *Elementary Linear Algebra*. The MacMillan Company, NY.